



UNIVERSITAT POLITÈCNICA
DE CATALUNYA
BARCELONATECH

UNIVERSITAT POLITÈCNICA DE CATALUNYA

GRAU EN INTEL·LIGÈNCIA ARTIFICIAL

Processos d'anàlisi intel·ligent de dades

Sistema intel·ligent de suport a la decisió per a la predicció de cancel·lacions en reserves hoteleres

*Integració de models de Machine Learning, clustering i regles de negoci per a la millora de
la presa de decisions*

Autors:

Joel Alfaro, Pablo Chacón, Pau Escobar , Blanca Mira, Daniel Pastor

ID Grup: 8

Data: 24 de maig de 2026

ÍNDEX

1. Introducció.....	5
2. Anàlisi de dades.....	6
2.1. Descripció del conjunt de dades.....	6
2.1.1. Origen de les dades.....	6
2.1.2. Estructura del dataset.....	7
2.1.3. Variables disponibles.....	7
2.1.4. Metadata del dataset.....	8
2.2. Anàlisi exploratòria de dades (EDA).....	11
2.2.1. Qualitat de les dades.....	11
2.2.2. Distribució de la Variable Objectiu.....	12
2.2.3. Distribució de les variables numèriques.....	12
2.2.4. Correlació entre variables numèriques.....	13
2.2.5. Relació entre variables numèriques i cancel·lació.....	15
2.2.6. Distribució de les variables categòriques.....	16
2.2.7. Taxa de cancel·lació per variable categòrica.....	17
2.2.8. Interacció entre deposit_type i market_segment.....	18
2.2.9. Canvis a la reserva i cancel·lació.....	18
2.2.10. Llista d'espera i cancel·lació.....	19
2.2.11. Lead time per estació i cancel·lació.....	19
2.2.12. Cancel·lació per país d'origen.....	20
2.2.13. Evolució temporal de reserves i ADR.....	21
3. Preprocessament de dades.....	22
3.1. Neteja inicial i tractament comú de les dades.....	22
3.2. Enginyeria de característiques.....	24
3.2.1. Preprocessament per al model predictiu de cancel·lació.....	24
3.2.2. Preprocessament específic per al clustering.....	26
3.2.3. Preprocessament de noves reserves en producció.....	28
3.3. Resultats del preprocessament.....	29
4. Definició del sistema.....	30
4.1. AI-Council Canvas.....	30
4.1.1. Descripció del cas d'ús.....	30
4.1.2. Elements del Canvas.....	31
4.2. Model de decisió.....	33
4.2.1. Descripció del procés de decisió.....	33
4.2.2. Integració model i regles.....	33
4.2.3. Tipus de decisions.....	34
4.2.4. Tipus d'usuaris.....	34
4.3. Arquitectura del sistema IDSS.....	36
4.3.1. Separació entre dataset del model i dataset del clustering.....	37
4.3.2. Fase d'entrenament.....	37
4.3.3. Fase de producció i inferència.....	38

4.3.4. Capa de decisió IDSS.....	38
4.3.5. Monitorització i feedback.....	39
4.3.6. Components del sistema.....	39
4.3.7. Flux d'informació.....	40
4.4. Consideracions d'implementació.....	41
4.4.1. Requisits de dades i transformacions en producció.....	41
4.4.2. Accés a dades i permisos.....	41
4.4.3. Eines de software utilitzades.....	41
5. Models predictius de cancel·lació.....	43
5.1. Estratègia de modelització.....	43
5.2. Models de referència i models base.....	44
5.3. Models avançats basats en arbres i ensemble learning.....	45
5.4. Comparació dels resultats.....	46
5.5. Selecció del model final.....	47
5.6. Interpretabilitat del model amb SHAP.....	48
6. Clustering.....	50
6.1. Primera aproximació al clustering i limitacions detectades.....	50
6.2. Errors metodològics de la primera versió.....	52
6.3. Replantejament del clustering.....	53
6.4. Selecció del nombre de clústers i comparació de models.....	55
6.5. Interpretació dels perfils obtinguts.....	56
6.6. Estabilitat interna dels clústers.....	61
6.7. Variables més discriminants entre clústers.....	62
6.8. Exportació del resultat i ús dins del sistema IDSS.....	63
7. Model de coneixement.....	64
7.1. Estructura general del model de coneixement.....	64
7.2. Principis experts de decisió.....	66
7.3. Tractament de deposit_type dins del sistema.....	67
7.4. Perfils operatius utilitzats.....	68
7.5. Funcionament de les regles per nivell de risc.....	70
7.6. Integració de les regles dins del dashboard.....	71
8. Interfície i dashboard operatiu.....	72
8.1. Arquitectura funcional de la interfície.....	72
8.2. Web pública de reserva.....	74
8.3. Dashboard intern del sistema.....	77
8.3.1. Fitxa d'intervenció per reserva.....	79
8.3.2. Agent d'email i comunicació amb el client.....	82
8.4. Flux complet d'ús del sistema.....	84
8.5. Valor aportat per la interfície.....	86
8.6. Limitacions i abast de la implementació.....	87
9. Validació.....	88
9.1. Enfocament general de la validació.....	88
9.2. Validació dels components individuals.....	1
9.3. Validació mitjançant casos d'ús.....	1

9.4. Limitacions de la validació.....	1
10. Treball futur i millores.....	1
11. Conclusions.....	1

1. Introducció

La cancel·lació de reserves és una de les principals fonts d'incertesa en la gestió hotelera, ja que afecta directament la planificació de l'ocupació, la gestió de l'inventari i l'optimització dels ingressos. En aquest context, anticipar quines reserves tenen més probabilitat de cancel·lar-se pot ajudar l'hotel a prendre decisions més informades. Tanmateix, el repte no és només predir el risc, sinó transformar aquesta predicció en accions operatives útils per al negoci.

Aquest projecte s'emmarca dins l'àmbit dels sistemes intel·ligents de suport a la decisió i té com a objectiu desenvolupar un sistema capaç d'estimar la probabilitat de cancel·lació d'una reserva hotelera a partir de la informació disponible en el moment de la seva creació. A diferència d'un model predictiu aïllat, la solució proposada integra aquesta probabilitat dins d'un flux de decisió més ampli, on també es tenen en compte el perfil de la reserva, el nivell de risc i criteris experts del domini hotelier.

Per assolir aquest objectiu, primer s'ha dut a terme una anàlisi exploratòria del conjunt de dades per entendre'n l'estructura, detectar problemes de qualitat i identificar variables rellevants. A continuació, s'ha definit un preprocessament específic per al model predictiu i s'han comparat diversos algorismes de classificació. El model final seleccionat ha estat XGBoost, ja que ha mostrat un bon equilibri entre capacitat predictiva, recall i F1-score, aspectes importants en un problema on interessa detectar cancel·lacions sense generar un volum excessiu de falses alarmes.

De manera complementària, s'ha incorporat un mòdul de clustering per identificar perfils operatius de reserva. Aquest perfilat no substitueix la predicció, sinó que aporta context a la decisió: dues reserves amb una probabilitat de cancel·lació semblant poden requerir actuacions diferents si corresponen, per exemple, a una reserva d'última hora, una reserva familiar, un viatger premium o un perfil corporatiu. Així, el sistema combina risc predictiu i segmentació per adaptar millor les recomanacions.

El sistema també inclou un model de coneixement basat en regles de negoci, definit externament, que transforma la probabilitat de cancel·lació i el perfil en accions concretes, com enviar un recordatori, preparar una trucada, revisar una reserva o escalar el cas a revenue management. Finalment, s'ha desenvolupat una interfície funcional formada per una web pública de reserva i un dashboard intern per al personal de l'hotel, on es mostren les reserves prioritzades, el risc, el perfil assignat, el valor econòmic i les accions recomanades.

En conjunt, el projecte proposa un prototip funcional d'IDSS hotelier que integra predicció, clustering, coneixement expert i interfície operativa. El seu valor principal no és només estimar cancel·lacions, sinó convertir aquesta estimació en suport real per a la presa de decisions, ajudant l'hotel a prioritzar recursos, reduir incertesa i protegir ingressos.

2. Anàlisi de dades

En aquest apartat s'analitza el conjunt de dades utilitzat com a base del projecte, amb l'objectiu d'entendre'n l'estructura, el contingut i la qualitat. Aquesta anàlisi és necessària per identificar quines variables poden ser més rellevants per a la predicció de cancel·lacions i per justificar, més endavant, les decisions adoptades durant el preprocessament i la modelització.

2.1. Descripció del conjunt de dades

El conjunt de dades utilitzat en aquest projecte recull informació històrica sobre reserves hoteleres corresponents a dos tipus d'establiments: City Hotel i Resort Hotel. Cada observació del dataset representa una reserva individual i inclou tant les característiques associades a la reserva, com l'antelació, la durada de l'estada, el tipus de client o el canal de distribució, com informació relativa al seu resultat final, en particular si la reserva ha estat cancel·lada o no.

La informació continguda en aquest conjunt de dades permet analitzar el comportament dels clients durant el procés de reserva i identificar quins factors estan relacionats amb la cancel·lació de les mateixes. Això el converteix en una base adequada per desenvolupar models predictius capaços d'estimar el risc de cancel·lació abans de la data d'arribada. A més, aquesta informació pot ser utilitzada per donar suport a la presa de decisions en la gestió hotelera, com ara la planificació de l'overbooking o l'adaptació d'estratègies comercials segons el perfil del client.

A continuació, es descriuen els principals aspectes del conjunt de dades, incloent el seu origen, la seva estructura i les variables que el componen.

2.1.1. Origen de les dades

El conjunt de dades utilitzat en aquest projecte prové del repositori públic Kaggle, concretament del dataset Hotel Booking Demand, accessible a través de l'enllaç oficial corresponent ([link Kaggle](#))

Aquest dataset recull informació històrica sobre reserves hoteleres reals i ha estat àmpliament emprat en estudis acadèmics i aplicacions pràctiques relacionades amb la predicció de cancel·lacions, l'anàlisi del comportament dels clients i la gestió de la demanda en el sector hotelier. La seva rellevància rau en la riquesa de variables que incorpora, les quals permeten caracteritzar de manera detallada tant les reserves com els perfils dels clients.

Pel que fa al procés d'obtenció, les dades han estat descarregades en format CSV i integrades en un entorn d'anàlisi basat en Python. Aquest entorn ha permès dur a terme les tasques de càrrega, exploració i preprocessament necessàries per transformar el conjunt de dades original en una estructura adequada per al desenvolupament de models predictius.

Per solucionar el gran volum de registres del conjunt de dades original, s'ha procedit a extreure una submostra de treball. Concretament, s'ha seleccionat un subconjunt de 5.000 línies de manera totalment aleatòria mitjançant l'ús de la funció *sample* de la llibreria Pandas. Aquest

mètode de mostreig simple garanteix la imparcialitat en la selecció, permetent treballar amb un conjunt més manejable sense comprometre la representativitat general de la informació.

2.1.2. Estructura del dataset

El conjunt de dades es presenta en forma de taula estructurada, on cada fila correspon a una reserva individual i cada columna representa una variable associada a aquesta reserva. Aquesta organització permet analitzar cada observació com una unitat independent, facilitant tant l'estudi descriptiu com el posterior desenvolupament de models predictius.

La granularitat de les dades és, per tant, a nivell de reserva, amb una freqüència basada en esdeveniments. És a dir, cada nova reserva registrada en el sistema genera una nova observació en el dataset, fet que permet capturar amb precisió el comportament dels clients en el moment de la reserva.

Pel que fa a la naturalesa de les variables, el conjunt de dades inclou diferents tipus d'informació. D'una banda, es disposa de variables numèriques, com ara *lead_time*, *adr* o *stays_in_week_nights*, que quantifiquen aspectes concrets de la reserva. D'altra banda, s'inclouen variables categòriques, com *hotel*, *country* o *market_segment*, que descriuen característiques qualitatives del client o del canal de reserva. Finalment, també es troben variables binàries, com *is_canceled* o *is_repeated_guest*, que indiquen la presència o absència de determinades condicions.

En relació amb la qualitat de les dades, s'observa la presència de valors absents en algunes variables. En particular, la variable *company* presenta un percentatge elevat de valors nuls, ja que només s'omple en el cas de reserves corporatives. De manera similar, la variable *agent* conté valors absents associats a reserves realitzades sense intermediari. Finalment, la variable *country* presenta un nombre molt reduït de valors desconeguts. Aquestes característiques seran analitzades i tractades de manera específica en la fase de preprocessament.

2.1.3. Variables disponibles

El conjunt de dades inclou un ampli conjunt de variables que permeten descriure de manera detallada les característiques de cada reserva, així com el perfil dels clients i les condicions en què s'ha realitzat. Aquestes variables poden agrupar-se segons la seva naturalesa i la informació que aporten dins del context del problema.

En primer lloc, es disposa de variables relacionades amb la reserva, que descriuen aspectes temporals i estructurals de la mateixa. Entre aquestes destaquen *lead_time*, que indica l'antelació amb què es realitza la reserva, així com les variables associades a la data d'arribada (*arrival_date_year*, *arrival_date_month*, *arrival_date_week_number*) i a la durada de l'estada (*stays_in_weekend_nights*, *stays_in_week_nights*).

En segon lloc, el dataset inclou variables que caracteritzen el client i la composició de la reserva, com el nombre d'adults, infants i nadons (*adults*, *children*, *babies*), el país d'origen (*country*) i el tipus de client (*customer_type*). Aquestes variables permeten identificar diferents perfils de clients i analitzar possibles diferències en el seu comportament.

Pel que fa a la dimensió comercial, es disposa de variables relacionades amb el canal de reserva i les condicions associades, com *market_segment*, *distribution_channel* i *deposit_type*. Aquestes variables són especialment rellevants, ja que poden reflectir diferències en les estratègies de comercialització i en el compromís del client amb la reserva.

A més, el conjunt de dades incorpora informació sobre l'històric del client, incloent indicadors com *is_repeated_guest*, *previous_cancellations* i *previous_bookings_not_canceled*. Aquestes variables permeten capturar el comportament passat del client, que pot ser un factor determinant en la predicció de futures cancel·lacions.

També es disposa de variables de caràcter econòmic, com *adr* (Average Daily Rate), que representa el preu mitjà diari de la reserva i proporciona informació rellevant sobre el valor econòmic associat a cada estada.

Finalment, la variable objectiu del problema és *is_canceled*, que indica si la reserva ha estat cancel·lada (valor 1) o no (valor 0). Aquesta variable constitueix la base per al desenvolupament dels models predictius.

Cal destacar que algunes variables, com *reservation_status* o *reservation_status_date*, contenen informació directament relacionada amb el resultat final de la reserva. La seva inclusió en el model podria introduir problemes de filtració d'informació (data leakage), ja que incorporen coneixement que no estaria disponible en el moment de fer la predicció. Per aquest motiu, aquestes variables seran tractades amb especial atenció i, si escau, eliminades en les etapes de preprocessament.

2.1.4. Metadata del dataset

La informació recollida en la taula de metadata permet disposar d'una visió estructurada del conjunt de dades, tant pel que fa al significat de cada variable com a la seva naturalesa, escala i possibles limitacions. Aquesta descripció resulta especialment útil per interpretar correctament els resultats de l'anàlisi exploratòria i per definir posteriorment un preprocessament coherent amb el tipus d'informació disponible.

METADATA – Hotel Booking Demand Dataset

Font: <https://www.kaggle.com/datasets/jessemostipak/hotel-booking-demand?resource=download> | Registres: 5.000 | Variables: 33

Variable	Significat	Tipus	Modalitats / Valors	Rang	Unitat de mesura	Valors Nulls	Procediment de mesura
hotel	Tipus d'hotel on es va fer la reserva	Categòrica	City Hotel, Resort Hotel	-	-	0	Registre del sistema de reserves
is_canceled	Indica si la reserva va ser cancel·lada (1) o no (0)	Binària	0, 1	-	-	0	Indicador binari del sistema

lead_time	Dies entre la data de reserva i la data d'arribada	Numèrica	-	0 – 629	Dies	0	Diferència entre data reserva i data d'arribada
arrival_date_year	Any d'arribada del client	Temporal	2015, 2016, 2017	-	Any	0	Data registrada al sistema de reserves
arrival_date_month	Mes d'arribada del client	Temporal	January – December	-	Mes	0	Data registrada al sistema de reserves
arrival_date_week_number	Número de setmana de l'any corresponent a l'arribada	Temporal	-	1 – 53	Número setmana	0	Calculat a partir de la data d'arribada
arrival_date_day_of_month	Dia del mes corresponent a l'arribada	Temporal	-	1 – 31	Dia	0	Data registrada al sistema de reserves
stays_in_weekend_nights	Nombre de nits de cap de setmana incloses a la reserva	Numèrica	-	0 – 8	Nits	0	Comptatge de nits de dissabte i diumenge
stays_in_week_nights	Nombre de nits entre setmana incloses a la reserva	Numèrica	-	0 – 19	Nits	0	Comptatge de nits de dilluns a divendres
gender_account	Gènere del titular del compte de reserva	Categòrica	Female, Male	-	-	0	Registre del perfil del client
adults	Nombre d'adults inclosos a la reserva	Numèrica	-	0 – 5	Persones	0	Declaració del client en el moment de reservar
children	Nombre de nens inclosos a la reserva	Numèrica	-	0 – 3	Persones	45	Declaració del client en el moment de reservar
babies	Nombre de bebès inclosos a la reserva	Numèrica	-	0 – 2	Persones	0	Declaració del client en el moment de reservar
meal	Tipus de règim d'àpats contractat	Categòrica	BB, HB, FB, SC, Undefined	-	-	0	Opció seleccionada durant la reserva
country	País d'origen del client	Geolocalització	Codi ISO 3166-1 alpha-3	-	-	27	Registre del perfil del client o passaport
market_segment	Segment de mercat del canal de reserva	Categòrica	Online TA, Offline TA/TO, Direct, Corporate, Groups, Complementary, Aviation	-	-	0	Classificació interna del canal de venda
distribution_channel	Canal de distribució de la reserva	Categòrica	TA/TO, Direct, Corporate, GDS	-	-	0	Registre del canal pel qual es va fer la reserva
is_repeated_guest	Indica si el client ja havia fet una reserva prèvia	Binària	0, 1	-	-	0	Indicador binari basat en historial de reserves
previous_cancellations	Nombre de reserves cancel·lades prèviament pel client	Numèrica	-	0 – 26	Nombre de cancel·lacions	0	Comptatge de l'historial de cancel·lacions

previous_bookings_not_canceled	Nombre de reserves anteriors no cancel·lades del client	Numèrica	-	0 – 54	Nombre de reserves	0	Comptatge de l'historial de reserves confirmades
reserved_room_type	Tipus d'habitació reservada originalment	Categòrica	A, B, C, D, E, F, G, H	-	-	0	Selecció durant el procés de reserva (codificada)
assigned_room_type	Tipus d'habitació assignada realment a l'arribada	Categòrica	A, B, C, D, E, F, G, H, I, K	-	-	0	Assignació realitzada per l'hotel en el check-in
booking_changes	Nombre de modificacions fetes sobre la reserva original	Numèrica	-	0 – 14	Nombre de canvis	0	Comptatge de modificacions al sistema
deposit_type	Tipus de dipòsit exigít per garantir la reserva	Categòrica	No Deposit, Non Refund, Refundable	-	-	0	Condicció contractual registrada al sistema
agent	Identificador de l'agència que va gestionar la reserva	Numèrica	-	1 – 531	ID agent	670	Codi intern de l'agència de viatges (pot ser nul si reserva directa)
company	Identificador de l'empresa que va fer la reserva	Numèrica	-	9 – 518	ID empresa	4731	Codi intern de l'empresa (molt freqüentment nul)
days_in_waiting_list	Dies que la reserva va estar en llista d'espera	Numèrica	-	0 – 391	Dies	0	Comptatge des de la sol·licitud fins a la confirmació
customer_type	Tipus de client segons la naturalesa de la reserva	Categòrica	Transient, Transient-Party, Contract, Group	-	-	0	Classificació interna del sistema de reserves
adr	Tarifa diària mitjana (Average Daily Rate)	Numèrica	-	0 – 451.5	Dòlars/nit	0	Mitjana del preu per habitació per nit durant l'estada
required_car_parking_spaces	Nombre de places d'aparcament sol·licitades	Numèrica	-	0 – 1	Places	0	Declaració del client en el moment de reservar
total_of_special_requests	Nombre de peticions especials fetes pel client	Numèrica	-	0 – 5	Nombre de peticions	0	Comptatge de sol·licituds addicionals del client
reservation_status	Estat final de la reserva	Categòrica	Check-Out, Canceled, No-Show	-	-	0	Estat registrat al sistema en el moment de tancament
reservation_status_date	Data en la qual es va actualitzar l'estat final de la reserva	Temporal	-	2014-10-17 – 2017-09-07	Data (YYYY-MM-DD)	0	Data registrada automàticament pel sistema

Taula 1. Resum de les principals variables incloses en el conjunt de dades, amb la seva descripció i tipologia.

2.2. Anàlisi exploratòria de dades (EDA)

L'objectiu de l'anàlisi exploratòria és comprendre l'estructura del conjunt de dades, detectar possibles problemes de qualitat i identificar patrons preliminars associats a la cancel·lació de reserves. Aquesta fase permet justificar les decisions posteriors de preprocessament, especialment pel que fa al tractament de valors absents, l'eliminació de variables problemàtiques, la generació de variables derivades i la selecció de predictors rellevants per als models.

A més, l'EDA aporta una primera lectura de negoci del problema. En aquest cas, no només interessa saber quines variables poden millorar la capacitat predictiva del model, sinó també entendre quins factors poden explicar situacions de risc en un context hotel·ler: antelació de la reserva, canal comercial, país d'origen, historial del client, durada de l'estada o valor econòmic de la reserva.

2.2.1. Qualitat de les dades

En primer lloc, s'ha revisat la qualitat general del conjunt de dades per identificar valors absents, registres duplicats i possibles incoherències lògiques. Aquesta revisió és necessària perquè qualsevol problema present en les dades originals pot afectar tant l'entrenament dels models com la interpretació posterior dels resultats.

Pel que fa als valors absents, s'han detectat quatre variables afectades. La variable `company` presenta el percentatge més elevat de valors nuls, amb un 94,62% del total, fet que indica que només està informada en casos molt concrets, habitualment vinculats a reserves corporatives. La variable `agent` també conté valors absents, amb un 13,40%, que poden interpretar-se com reserves gestionades sense intermediari. En canvi, `children` i `country` presenten absències més limitades, amb un 7,28% i un 0,54% respectivament.

Aquests patrons indiquen que els valors nuls no s'han de tractar tots de la mateixa manera. En alguns casos, com `children`, la imputació amb 0 és coherent amb la interpretació de no presència d'infants. En altres casos, com `agent` i `company`, la presència o absència d'informació pot ser més útil que el codi original, motiu pel qual posteriorment es transformen en indicadors binaris (`has_agent` i `has_company`).

També s'han identificat 270 registres duplicats, que representen un 5,4% del conjunt de dades. Aquests registres s'han considerat redundants i s'han eliminat en la fase de preprocessament per evitar que una mateixa reserva pugui influir més d'una vegada en l'entrenament o en l'avaluació dels models.

Finalment, s'han detectat algunes incoherències lògiques: 9 reserves amb zero hostes i 34 reserves amb zero nits d'estada. No s'han observat valors negatius en la variable `adr`. Les reserves amb zero hostes o zero nits no representen situacions operatives habituals en un context hotel·ler, de manera que s'han tractat com a casos a revisar durant la neteja inicial.

2.2.2. Distribució de la Variable Objectiu

La variable objectiu del projecte és `is_canceled`, que indica si una reserva ha estat cancel·lada o no. En la mostra analitzada, el 38,06% de les reserves corresponen a cancel·lacions, mentre que el 61,94% restant corresponen a reserves completades.




Figura 1: Distribució de la variable objectiu (cancel·lat vs. no cancel·lat)

Aquesta distribució mostra un desequilibri moderat entre classes. Tot i que la classe majoritària és la de reserves no cancel·lades, la proporció de cancel·lacions és prou elevada per considerar-la un fenomen rellevant des del punt de vista del negoci. Aproximadament dues de cada cinc reserves no arriben a materialitzar-se, fet que pot afectar de manera directa la planificació de l'ocupació, la gestió de recursos i els ingressos esperats.

Des del punt de vista de la modelització, aquest desequilibri obliga a no basar l'avaluació únicament en l'accuracy. Per aquest motiu, en les fases posteriors es consideren mètriques com el recall, l'F1-score i l'AUC, que permeten valorar millor la capacitat del model per detectar cancel·lacions sense generar un nombre excessiu de falsos positius.

2.2.3. Distribució de les variables numèriques

L'anàlisi de les distribucions de les principals variables numèriques revela que la major part presenten una asimetria positiva marcada. En concret, `lead_time`, `days_in_waiting_list`, `previous_cancellations` i `previous_bookings_not_canceled` mostren una concentració elevada de valors propers a zero i una cua llarga cap a la dreta, indicant la presència de valors extrems puntuals. Aquestes distribucions no normals hauran de tenir-se en compte durant el preprocessament, especialment a l'hora d'escollir estratègies d'imputació i d'escalar variables per als models.

Variables com `total_of_special_requests` o `booking_changes` presenten també una distribució molt esbiaixada cap a zero, fet que indica que la majoria de reserves no inclouen peticions especials ni modificacions. Tot i això, la presència d'aquests valors pot ser informativa, com es veurà en les seccions posteriors. Finalment, `adr` presenta una distribució aproximadament unimodal, amb alguns valors extrems que podrien correspondre a reserves de caràcter especial o errors de registre.




Figura 2: Histogrames de les variables numèriques principals

2.2.4. Correlació entre variables numèriques

L'anàlisi de les variables numèriques mostra que `lead_time` és la variable amb una relació més clara amb la cancel·lació. La seva correlació amb `is_canceled` és positiva i és la més elevada entre les variables numèriques analitzades. La comparació de distribucions mostra que les reserves cancel·lades tendeixen a presentar una antelació clarament superior a les no cancel·lades: la mediana de `lead_time` en les reserves cancel·lades se situa al voltant dels 115 dies, mentre que en les no cancel·lades és aproximadament de 45 dies.




Figura 3: Matriu de correlació entre variables numèriques seleccionades

Altres variables també mostren relacions interessants, encara que menys intenses. `total_of_special_requests` presenta una correlació negativa amb la cancel·lació, fet que suggereix que els clients que fan peticions especials poden estar més implicats amb l'estada. De manera similar, `booking_changes` mostra una relació negativa: les reserves que han estat modificades tendeixen a cancel·lar-se menys, cosa que s'analitzarà amb més detall en una secció posterior.

Pel que fa a `required_car_parking_spaces`, també s'observa una relació negativa amb la cancel·lació, tot i que la variable és molt específica i presenta poca variabilitat. `previous_cancellations` mostra una correlació positiva amb la variable objectiu, consistent amb la hipòtesi que el comportament passat del client és un indicador rellevant del comportament futur. Finalment, variables com `adr` o `total_nights` no mostren per si soles una separació clara entre reserves cancel·lades i no cancel·lades, tot i que poden aportar informació en combinació amb altres variables.

La matriu de correlació no mostra problemes greus de multicolinealitat entre predictors numèrics. La relació més destacable és entre `adr` i `total_guests`, que resulta esperable, ja que una reserva amb més hostes pot tenir un valor total més elevat. En qualsevol cas, aquesta correlació no és prou alta com per comprometre la modelització.

2.2.5. Relació entre variables numèriques i cancel·lació

La comparació de les distribucions de les principals variables numèriques entre reserves cancel·lades i no cancel·lades confirma i aprofundeix els patrons observats en la matriu de correlació.

En el cas de `lead_time`, la diferència és especialment pronunciada: les reserves cancel·lades presenten una distribució desplaçada clarament cap a valors més alts, amb una mediana notablement superior. Aquest resultat té una interpretació de negoci coherent: com més temps passa entre el moment de la reserva i la data d'arribada, més probable és que canviïn les circumstàncies del client. Per tant, les reserves fetes amb molta antelació poden requerir accions preventives o recordatoris en fases posteriors del sistema.

Pel que fa a `total_nights`, les distribucions entre les dues classes presenten menys diferències, tot i que s'observa una certa tendència que les reserves cancel·lades inclouen estades lleugerament més llargues. En el cas de l'ADR, el violin plot mostra una dispersió similar en ambdues classes, però amb algunes diferències en els valors centrals que suggereixen que el preu pot tenir un efecte moderat sobre la probabilitat de cancel·lació.

L'anàlisi del comportament del client revela que `previous_cancellations` és clarament més alta entre les reserves que acaben cancel·lant-se, confirmant que l'historial de cancel·lació és un predictor rellevant. Per contra, `total_of_special_requests` és significativament més baixa en les reserves cancel·lades, evidenciant que els clients que fan peticions especials demostren un major grau de compromís amb l'estada. Finalment, la taxa de cancel·lació dels clients recurrents (`is_repeated_guest = 1`) és considerablement inferior a la dels clients nous, cosa que reflecteix un vincle de confiança preexistent amb l'hotel.




Figura 4: Boxplots i violin plots de les variables numèriques principals per cancel·lació

2.2.6. Distribució de les variables categòriques

L'anàlisi de la distribució de les variables categòriques principals proporciona una visió de l'estructura general del conjunt de dades. Pel que fa al tipus d'hotel, la mostra conté una proporció similar de City Hotel i Resort Hotel, tot i que el primer és lleugerament més freqüent. Quant al segment de mercat, Online TA és el canal predominant, seguit d'Offline TA/TO i Direct. Les reserves de tipus Groups i Corporate representen una fracció menor del total. El tipus de client Transient és amb diferència el més habitual, mentre que Contract i Group apareixen amb molta menys freqüència.

Pel que fa al tipus de dipòsit, la gran majoria de reserves corresponen a la categoria No Deposit, mentre que les categories Non Refund i Refundable presenten volums molt inferiors. Aquesta distribució és important de tenir en compte perquè algunes categories minoritàries poden mostrar taxes de cancel·lació molt extremes per raons associades a la seva pròpia naturalesa, com s'analitzarà en la secció següent.




Figura 5: Distribució de les variables categòriques seleccionades

2.2.7. Taxa de cancel·lació per variable categòrica

L'anàlisi de les taxes de cancel·lació per a les principals variables categòriques mostra diferències rellevants que orienten la selecció de predictors.

Deposit type. Les reserves classificades com a Non Refund presenten una taxa de cancel·lació del 99,5% (n = 645), un comportament altament contraindiciu que probablement reflecteix una convenció de registre del sistema: és probable que només es marquin com a Non Refund aquelles reserves que tenien un dipòsit inicial i que s'han cancel·lat retenint-lo. A més, aquesta variable presenta data leakage, ja que incorpora informació que només es coneix a posteriori del resultat. Per tant, serà eliminada en la fase de preprocessament.

Market segment. Groups lidera amb un 64,7%, possiblement per la incertesa en la confirmació definitiva del nombre de participants. Online TA (37,1%) i Offline TA/TO (34,2%) se situen per sobre de la mitjana, mentre que Direct (13,4%) i Complementary (6,7%) mostren les taxes més baixes.

Distribution channel. TA/TO (42,2%) és el canal amb la taxa més alta, coherent amb les polítiques de cancel·lació flexibles de les agències i plataformes intermediàries. El canal Direct (16,4%) és significativament millor, reflectint una relació més directa i compromesa amb l'hotel.

Customer type. Els segments Transient i Transient-Party mostren les taxes de cancel·lació més elevades, mentre que Contract i Group presenten valors inferiors, probablement per la major rigidesa contractual associada a aquests tipus de reserva.

Hotel. El City Hotel presenta una taxa de cancel·lació superior a la del Resort Hotel, cosa que pot estar relacionada amb un tipus de demanda diferent, generalment més vinculada a viatges de negoci o a reserves de curta antelació amb més flexibilitat.




Figura 6: Taxa de cancel·lació per deposit_type, market_segment, distribution_channel i customer_type

2.2.8. Interacció entre deposit_type i market_segment

Per aprofundir en la relació entre les variables categòriques, s'ha analitzat la interacció entre `deposit_type` i `market_segment` mitjançant un mapa de calor de la taxa de cancel·lació per a cada combinació. Aquesta anàlisi permet detectar si l'efecte del canal de reserva varia en funció del tipus de dipòsit associat.

Els resultats mostren que la combinació Non Refund amb qualsevol segment de mercat presenta taxes de cancel·lació molt elevades, confirmant la problemàtica ja descrita d'aquesta variable. Un cop descartades les combinacions associades a Non Refund, s'observa que les reserves de Groups sense dipòsit mantenen taxes altes, i que les reserves directes sense dipòsit presenten les taxes més baixes de manera consistent. Aquesta anàlisi reforça la idea que el canal de distribució i les condicions contractuals actuen conjuntament sobre la probabilitat de cancel·lació.




Figura 7: Mapa de calor de la taxa de cancel·lació per `deposit_type` x `market_segment` (combinacions amb $n \geq 20$)

2.2.9. Canvis a la reserva i cancel·lació

L'anàlisi de la variable `booking_changes` revela un patró contraintuïtiu però sòlid: les reserves sense cap canvi presenten la taxa de cancel·lació més alta (41,7%), mentre que les que en presenten almenys un cauen dràsticament (14,7% per a 1 canvi, al voltant del 19% per a 2 o més). La interpretació és que realitzar canvis és un senyal d'engagement actiu: el client que modifica dates o tipus d'habitació manté un interès real en l'estada. Qui no fa cap canvi pot estar més absent de la reserva.

Aquesta relació negativa i robusta fa de `booking_changes` un predictor valuós malgrat la seva distribució molt esbiaixada cap a zero. Cal tenir en compte, però, que aquesta variable pot no estar disponible en el moment inicial de la predicció si es vol aplicar el sistema en el moment de la reserva, de manera que s'ha tractat amb especial atenció en la fase de preprocessament.




Figura 8: Taxa de cancel·lació per nombre de canvis a la reserva i distribució de booking_changes per cancel·lació

2.2.10. Llista d'espera i cancel·lació

Un altre aspecte analitzat és la relació entre `days_in_waiting_list` i la cancel·lació. La gran majoria de reserves no han passat per cap llista d'espera (més del 95% presenten un valor de 0), de manera que la variable presenta una asimetria molt pronunciada. Entre les reserves que sí que han estat en llista d'espera, la taxa de cancel·lació és inferior a la de les reserves sense espera, cosa que pot indicar que els clients que han hagut d'esperar per confirmar la seva reserva estan més compromesos amb l'estada quan finalment la obtenen.

Tot i que aquesta variable presenta poca variabilitat, la seva distribució i la seva relació amb la cancel·lació aporten informació addicional que pot ser d'utilitat com a senyal complementari en el model.




Figura 9: Taxa de cancel·lació per presència o absència de llista d'espera i distribució dels dies d'espera

2.2.11. Lead time per estació i cancel·lació

L'anàlisi del `lead_time` en funció de l'estació d'arribada revela que la tardor és l'estació amb el lead time mitjà més alt (al voltant dels 100 dies), seguida de l'estiu i la primavera; l'hivern presenta els valors més baixos (inferiors a 50 dies de mitjana). Més rellevant és la comparació

per cancel·lació: en totes les estacions, les reserves cancel·lades mostren un lead time significativament superior a les no cancel·lades. La separació és especialment pronunciada a la tardor i l'estiu.

Aquest resultat suggereix que la variable temporal associada a l'estació pot ser útil per contextualitzar el risc associat al lead time, i reforça la conveniència d'incloure variables estacionals com a predictors del model.




Figura 10: Lead time per estació d'arribada i per cancel·lació

2.2.12. Cancel·lació per país d'origen

L'anàlisi de la taxa de cancel·lació per país d'origen, considerant els 12 països amb més reserves, mostra diferències significatives entre orígens. Alguns països presenten taxes que superen el 50%, mentre que d'altres es mantenen molt per sota de la mitjana global. Aquesta variabilitat suggereix que el país d'origen del client pot ser un predictor rellevant, tot i que cal tractar-lo amb prudència atesa la seva alta cardinalitat i la presència de categories poc freqüents.

Per aquest motiu, en la fase de preprocessament es genera una variable derivada `country_risk` que agrupa els països en nivells de risc, evitant la fragmentació excessiva que podria introduir una codificació directa.




Figura 11: Taxa de cancel·lació als 12 països amb més reserves

En el gràfic s'observa la taxa de cancel·lació dels països amb més reserves. El país amb una taxa més elevada és **Portugal (PRT)**, amb gairebé un 59% de cancel·lacions, molt per sobre de la resta. També destaquen **Itàlia (ITA)** i **Brasil (BRA)**, amb valors al voltant del 45% i el 40%, respectivament, així com **Suïssa (CHE)**, que se situa per sobre del 30%. En una posició intermèdia apareixen **Irlanda (IRL)**, **Espanya (ESP)**, **Estats Units (USA)** i **Països Baixos (NLD)**. En canvi, els països amb una taxa de cancel·lació més baixa dins d'aquest grup són **Alemanya (DEU)**, **Bèlgica (BEL)**, **França (FRA)** i **Regne Unit (GBR)**, tots ells amb percentatges propers o inferiors al 20%.

2.2.13. Evolució temporal de reserves i ADR

S'observa una clara estacionalitat: els mesos d'abril a agost concentren el major volum de reserves, amb un màxim a maig-juny, i un segon pic secundari a l'octubre. Els mesos d'hivern registren els volums mínims. L'ADR segueix el mateix patró estacional, assolint el màxim a l'agost i caient a la tardor. Existeix també una tendència alcista interanual: el 2017 supera el 2016 en ADR pràcticament tots els mesos, indicant creixement del negoci durant el període estudiat.

Cal interpretar aquesta anàlisi temporal amb prudència, ja que el conjunt de dades correspon a una mostra del total de reserves i la cobertura pot no ser homogènia entre els diferents anys. Tot i això, les variables temporals, especialment el mes d'arribada i l'estació, capturen bona part d'aquesta variabilitat i es consideren predictors útils per al model.




Figura 12: Evolució mensual del nombre de reserves i de l'ADR mitjà per any

3. Preprocessament de dades

L'objectiu del preprocessament és transformar el conjunt de dades original en representacions adequades per als diferents components del sistema intel·ligent de suport a la decisió. En aquest projecte, el preprocessament no s'ha plantejat com una única transformació comuna per a tot el sistema, sinó com un conjunt de processos diferenciats segons la finalitat de cada mòdul.

En concret, s'han definit tres fluxos de preprocessament. El primer està orientat al model predictiu de cancel·lació i té com a objectiu generar una matriu numèrica compatible amb els models de classificació supervisada. El segon està orientat al clustering, on l'objectiu no és predir la cancel·lació, sinó obtenir perfils interpretables de reserves o clients; per aquest motiu, s'ha utilitzat una representació més compacta i específica, evitant una codificació one-hot d'alta dimensionalitat. Finalment, s'ha definit un preprocessament específic per a noves reserves en producció, necessari perquè el sistema pugui rebre una reserva nova, transformar-la de manera coherent i generar tant la probabilitat de cancel·lació com el perfil operatiu corresponent.

Aquesta separació és important perquè cada component del sistema té una necessitat diferent. El model predictiu requereix una representació optimitzada per al rendiment en classificació, mentre que el clustering necessita una representació més interpretable i equilibrada per identificar grups de comportament. El preprocessament en producció, per la seva banda, ha de garantir que qualsevol nova reserva pugui ser tractada amb el mateix criteri que les dades utilitzades durant l'entrenament.

3.1. Neteja inicial i tractament comú de les dades

Abans de construir els diferents fluxos de preprocessament, s'ha aplicat una primera etapa comuna de neteja sobre el conjunt de dades original. Aquesta etapa permet corregir problemes de qualitat detectats durant l'EDA i generar una base consistent sobre la qual construir tant el model predictiu com el clustering.

En primer lloc, s'han identificat i eliminat els registres duplicats detectats durant l'anàlisi exploratòria. Aquesta decisió garanteix que cada observació representi una reserva única i evita que una mateixa reserva pugui influir més d'una vegada en l'entrenament o en l'avaluació dels models.

A continuació, s'ha dut a terme un tractament dels valors absents tenint en compte el significat semàntic de cada variable. En el cas de `children`, els valors nuls s'han substituït per 0, ja que la seva absència s'interpreta com la no presència d'infants a la reserva. Pel que fa a `country`, els valors desconeguts s'han agrupat sota una categoria explícita, de manera que aquesta manca d'informació no es perdi durant el procés de transformació.

Les variables `agent` i `company` presentaven un patró de valors absents diferent. En aquest cas, els nuls no s'han interpretat com errors o absències aleatòries, sinó com indicadors que la reserva no havia estat gestionada per cap agent o no estava associada a cap empresa. Per aquest motiu, aquestes variables no s'han imputat amb un codi numèric arbitrari, sinó que s'han transformat en dues variables binàries: `has_agent` i `has_company`. Aquestes noves variables

indiquen simplement la presència o absència d'intermediari o empresa. Un cop generats aquests indicadors, les columnes originals `agent` i `company` s'han eliminat.

També s'ha aplicat una reducció de la fragmentació de la variable `country`. En lloc de mantenir tots els països originals com a categories independents, s'han conservat els països més freqüents i la resta s'han agrupat sota una categoria residual. Aquesta decisió evita que categories amb molt poques observacions introdueixin soroll o generin una representació massa dispersa.

Un altre punt important ha estat l'eliminació de variables amb risc de **data leakage** o no disponibles en el moment real de la predicció. Concretament, s'han eliminat `reservation_status` i `reservation_status_date`, ja que descriuen directament el resultat final de la reserva. També s'han descartat `assigned_room_type`, `booking_changes` i `days_in_waiting_list`, perquè corresponen a informació que pot generar-se o actualitzar-se en fases posteriors del cicle de vida de la reserva i que, per tant, no estaria necessàriament disponible en el moment inicial en què el sistema ha de generar la recomanació.

Finalment, s'ha prestat especial atenció a la variable `deposit_type`. Durant l'EDA s'ha observat que aquesta variable presentava un comportament molt anòmal, especialment en la categoria `Non Refund`, amb una taxa de cancel·lació extremadament elevada. Per aquest motiu, s'ha decidit no utilitzar-la com a entrada del model predictiu, ja que podria introduir una dependència excessiva respecte al resultat final o a convencions internes de registre. No obstant això, aquesta variable es pot conservar com a informació contextual visible en el dashboard, perquè pot ajudar l'usuari a interpretar les condicions comercials de la reserva sense intervenir en el càlcul de la probabilitat de cancel·lació.

3.2. Enginyeria de característiques

Amb l'objectiu d'enriquir la representació de cada reserva i reduir redundàncies, s'han generat diverses variables derivades a partir de les variables originals.

En primer lloc, s'ha creat `total_nights`, que resumeix la durada total de l'estada a partir de la suma de `stays_in_weekend_nights` i `stays_in_week_nights`. Un cop creada aquesta variable, les dues columnes originals es poden eliminar de la representació final per evitar duplicar informació.

També s'ha generat `total_guests`, calculada com la suma d'`adults`, `children` i `babies`. Aquesta variable permet representar de manera compacta la mida del grup associat a la reserva. Després de generar-la, les variables originals de composició del grup poden retirar-se de la matriu final del model.

A partir d'aquestes variables s'ha construït `adr_per_guest`, que representa el preu mitjà diari per hoste. Aquesta variable permet capturar millor la relació entre el preu de la reserva i el nombre de persones allotjades. Per evitar divisions per zero, en els casos en què el nombre total d'hostes és nul s'ha utilitzat un denominador mínim d'1.

També s'ha creat `is_family_booking`, una variable binària que indica si la reserva inclou infants o nadons. Aquesta variable és rellevant perquè les reserves familiars poden presentar necessitats logístiques diferents, com llits addicionals, habitacions comunicades, serveis infantils o horaris més específics.

Finalment, s'ha generat `country_risk`, una variable derivada del país d'origen que classifica cada reserva en tres nivells de risc de cancel·lació: `Low`, `Medium` i `High`. Aquesta classificació es basa en la taxa de cancel·lació observada per país dins del conjunt de dades. D'aquesta manera, es conserva informació contextual rellevant sense introduir una codificació excessivament fragmentada de la variable `country`.

3.2.1. Preprocessament per al model predictiu de cancel·lació

El primer flux de preprocessament s'ha dissenyat específicament per entrenar el model supervisat de predicció de cancel·lacions. L'objectiu és obtenir una matriu numèrica neta, sense valors absents i compatible amb els diferents algorismes de classificació avaluats.

Un cop aplicada la neteja inicial i generades les variables derivades, s'ha separat la variable objectiu `is_canceled` de la resta de variables explicatives. El conjunt de dades s'ha dividit de manera estratificada per mantenir una proporció similar de reserves cancel·lades i no cancel·lades en els diferents subconjunts. Aquesta decisió és especialment important perquè la classe de reserves cancel·lades és minoritària, però té un interès central per al sistema.

Per garantir un tractament sistemàtic i reproduïble, s'ha construït un pipeline de preprocessament mitjançant `ColumnTransformer`, que aplica transformacions diferenciades a tres grups de variables: numèriques, binàries i categòriques. Les variables numèriques utilitzades en el model supervisat són:

```
lead_time  
arrival_date_week_number  
arrival_date_day_of_month  
previous_cancellations  
previous_bookings_not_canceled  
adr  
required_car_parking_spaces  
total_of_special_requests  
total_nights  
total_guests  
adr_per_guest
```

Aquestes variables s'han imputat amb la mediana i posteriorment s'han escalat mitjançant `StandardScaler`. L'escalat és important perquè algunes variables presenten rangs molt diferents, i aquesta transformació evita que les variables amb valors numèrics més grans tinguin un pes desproporcionat en determinats models. Les variables binàries utilitzades són:

```
is_repeated_guest  
has_agent  
has_company  
is_family_booking
```

Aquestes variables s'han mantingut en format 0/1. En aquest bloc només s'ha aplicat una imputació amb el valor més freqüent per assegurar la robustesa del pipeline davant possibles valors absents residuals o dades incompletes en producció. Cal destacar que `is_repeated_guest` no s'ha eliminat, ja que aporta informació sobre la relació prèvia del client amb l'hotel. Les variables categòriques utilitzades en el model són:

```
hotel  
arrival_date_year  
arrival_date_month  
gender_account  
meal  
country_risk  
market_segment  
distribution_channel  
reserved_room_type  
customer_type
```

Aquestes variables s'han tractat mitjançant imputació del valor més freqüent i codificació one-hot amb l'opció `handle_unknown="ignore"`. Aquesta opció és necessària perquè permet gestionar categories no observades durant l'entrenament sense provocar errors en validació, test o producció.

Un aspecte important és que `arrival_date_year` s'ha tractat com a variable categòrica i no com a numèrica. Aquesta decisió és coherent amb el significat de la variable, ja que l'any d'arribada no representa una magnitud contínua comparable a variables com `lead_time` o `adr`, sinó un període temporal concret. Per tant, la seva codificació categòrica evita imposar una relació ordinal artificial entre anys.

També cal remarcar que `deposit_type` no s'ha inclòs dins del conjunt de variables del model predictiu. Tot i que aquesta variable presentava una relació molt forta amb la cancel·lació en l'EDA, s'ha considerat problemàtica pel seu possible caràcter de data leakage o per la seva dependència de processos interns de registre. Per aquest motiu, queda fora de la matriu d'entrenament del model, tot i que pot conservar-se com a informació contextual per al dashboard.

El preprocessador s'ha ajustat únicament sobre el conjunt d'entrenament i s'ha aplicat posteriorment als conjunts de validació i test sense cap ajust addicional. Aquesta estratègia evita filtracions d'informació entre particions i assegura una avaluació més realista del rendiment dels models.

Un cop aplicat el pipeline, la representació final del model queda formada per **65 variables processades**, resultat de combinar les variables numèriques escalades, les variables binàries i les columnes generades per la codificació one-hot de les variables categòriques. Per garantir la seva reutilització en producció, el preprocessador entrenat s'ha desat com a artefacte persistent (`preprocessor.joblib`), de manera que pugui aplicar-se a noves reserves amb exactament les mateixes transformacions.

3.2.2. Preprocessament específic per al clustering

El segon flux de preprocessament s'ha definit específicament per al mòdul de clustering. A diferència del model supervisat, l'objectiu no és predir directament si una reserva serà cancel·lada, sinó identificar perfils de reserves o clients amb característiques similars.

Inicialment es va considerar aplicar clustering sobre les dades preprocessades del model supervisat. Tanmateix, aquesta opció no era adequada, ja que la codificació one-hot genera una representació d'alta dimensionalitat en què les variables categòriques poden dominar artificialment les distàncies entre observacions. Això dificulta l'obtenció de grups interpretables i pot provocar que els clústers reflecteixin més la codificació de les dades que no pas patrons reals de comportament.

Per aquest motiu, s'ha construït un dataset específic per al clustering, amb una representació més compacta i orientada a la interpretabilitat. Les variables numèriques directes emprades per al clustering són:

<code>lead_time</code> <code>total_nights</code> <code>total_guests</code> <code>adr_per_guest</code> <code>total_of_special_requests</code> <code>is_family_booking</code>
--

previous_cancellations has_agent is_repeated_guest
--

Les variables categòriques s'han codificat mitjançant mapatges simples i compactes, evitant la codificació one-hot. Concretament, `hotel` s'ha transformat en una variable binària `is_resort`, que pren el valor 1 si la reserva correspon a un `Resort Hotel` i 0 si correspon a un `City Hotel`.

Les variables `meal`, `market_segment`, `customer_type` i `country_risk` s'han convertit en codis numèrics agrupats segons el seu significat operatiu. Aquesta estratègia permet conservar informació qualitativa rellevant sense augmentar artificialment la dimensionalitat de l'espai de clustering. Els mapatges utilitzats són els següents:

meal: Undefined = 0 SC = 1 BB = 2 HB = 3 FB = 4	country_risk: Low = 0 Medium = 1 High = 2
market_segment: Groups = 0 Corporate = 1 Offline TA/TO = 2 Direct = 3 Online TA = 4	customer_type: Contract = 0 Group = 1 Transient-Party = 2 Transient = 3

A més, s'han generat dues variables derivades específiques per al clustering. La primera és `spend_total`, que aproxima el valor econòmic total de la reserva a partir de `adr_per_guest`, `total_guests` i `total_nights`. Aquesta variable permet diferenciar reserves amb diferent impacte econòmic, independentment de la seva probabilitat de cancel·lació.

La segona és `booking_complexity`, que resumeix la complexitat operativa de la reserva combinant el nombre de peticions especials i la presència d'una reserva familiar. Aquesta variable és útil per identificar reserves que poden requerir més atenció logística, encara que no siguin necessàriament les de més risc predictiu.

En total, la matriu utilitzada per al clustering conté **16 variables**. Abans d'aplicar els algorismes, aquestes variables s'han imputat amb la mediana quan era necessari i s'han estandarditzat amb `StandardScaler`. Aquesta etapa és imprescindible perquè els mètodes de clustering utilitzats es basen en distàncies i són sensibles a l'escala de les variables.

Per seleccionar el nombre òptim de clústers, s'han avaluat valors de K entre 2 i 8 mitjançant diverses mètriques internes: inèrcia, silhouette, índex de Davies-Bouldin i índex de

Calinski-Harabasz. La silhouette s'ha utilitzat com a criteri principal, però la decisió final també s'ha validat en funció de la interpretabilitat dels perfils resultants.

Finalment, s'han comparat tres models amb el nombre de clústers seleccionat: K-means, clustering jeràrquic amb enllaç Ward i Gaussian Mixture Model. El model final s'ha escollit combinant el rendiment segons les mètriques internes amb la coherència interpretativa dels grups. A més, s'ha inclòs una anàlisi de les variables més discriminants entre clústers mitjançant un Random Forest auxiliar, utilitzat únicament amb finalitat interpretativa.

El resultat final d'aquest flux és un fitxer CSV que conserva les columnes del dataset original i afegeix una nova columna: cluster. Aquesta decisió permet mantenir una sortida neta i desacoblada, deixant la traducció dels clústers a perfils operatius i la generació de recomanacions per a la capa posterior del sistema IDSS.

3.2.3. Preprocessament de noves reserves en producció

El tercer flux de preprocessament correspon al funcionament del sistema en producció o en la interfície del dashboard. L'objectiu és que una nova reserva pugui ser transformada automàticament per alimentar tant el model predictiu com el mòdul d'assignació de perfil.

Quan una nova reserva entra al sistema, pot no contenir directament totes les variables derivades generades durant l'entrenament. Per aquest motiu, el motor IDSS aplica primer una etapa d'enriquiment de dades. En aquesta etapa es generen automàticament variables com `total_nights`, `total_guests`, `adr_per_guest`, `has_agent`, `has_company`, `is_family_booking`, `country_risk`, `spend_total` i `booking_complexity`. També es defineixen valors per defecte raonables per a variables que puguin faltar en una simulació o en una entrada parcial.

Després d'aquest enriquiment, la nova reserva segueix dos camins paral·lels. D'una banda, es transforma amb el preprocessador del model predictiu (`preprocessor.joblib`), de manera que la matriu resultant tingui exactament les mateixes columnes i la mateixa codificació que les dades d'entrenament. A partir d'aquesta representació, el model XGBoost genera la probabilitat de cancel·lació.

D'altra banda, la mateixa reserva es transforma segons el preprocessament específic del clustering. En aquest cas, es construeixen les variables compactes utilitzades per a la segmentació, s'aplica l'escalat corresponent i s'assigna la reserva al clúster més proper segons la distància als centroides calculats a partir de les reserves històriques. D'aquesta manera, el sistema pot associar cada nova reserva a un perfil operatiu.

Finalment, la probabilitat de cancel·lació i el perfil assignat s'envien a la capa de decisió. Aquesta capa aplica les regles de negoci definides en el model de coneixement i genera una recomanació operativa accionable, que posteriorment es mostra al dashboard.

3.3. Resultats del preprocessament

Com a resultat del preprocessament, el projecte genera un conjunt d'artefactes diferenciats per a cada component del sistema. Aquesta separació permet desacoblar la fase de modelització supervisada, el mòdul de clustering i el funcionament operatiu del dashboard.

Per al **model predictiu** s'han generat els conjunts d'entrenament, validació i test, juntament amb els vectors objectiu corresponents. La partició s'ha fet de manera estratificada, de manera que la proporció de reserves cancel·lades es manté consistent entre els diferents subconjunts. En la versió final utilitzada pel sistema, el preprocessador genera una matriu de **65 variables processades**, formada per variables numèriques escalades, variables binàries i variables categòriques codificades mitjançant one-hot encoding.

S'ha verificat que els conjunts preprocessats no contenen valors nuls ni infinits i que les variables binàries i one-hot presenten valors coherents. El preprocessador ajustat s'ha desat com a `preprocessor.joblib`, fet que permet aplicar exactament les mateixes transformacions a noves reserves en fase de producció.

Per al clustering s'ha generat un dataset específic de **16 variables**, amb una representació orientada a la interpretabilitat. Aquest dataset evita l'ús de one-hot encoding i incorpora variables derivades com `spend_total` i `booking_complexity`. El resultat final del procés és el fitxer `hotel_clustering_output.csv`, que conserva les columnes del dataset original i afegeix únicament la columna `cluster`.

Per al funcionament en **producció** s'ha definit un flux de transformació capaç de processar una nova reserva, generar les variables derivades necessàries, aplicar el preprocessament del model predictiu, assignar el perfil de clustering corresponent i preparar la informació per a la capa de decisió.

Aquesta estructura confirma que el preprocessament no és únicament una etapa prèvia a l'entrenament del model, sinó una peça central del sistema. La seva correcta definició permet que el model predictiu, el clustering i la capa de decisió treballin amb representacions coherents, evitant inconsistències entre el desenvolupament i la producció.

4. Definició del sistema

En aquest apartat es presenta la definició general del sistema proposat, abordant-lo des d'una perspectiva funcional i arquitectònica. L'objectiu és descriure com es transforma el problema de predicció de cancel·lacions en un sistema intel·ligent de suport a la decisió capaç d'integrar models basats en dades, coneixement expert i criteris operatius. Per fer-ho, es parteix del cas d'ús i del seu context de negoci, es defineix el model de decisió i, finalment, es descriu l'arquitectura general del sistema i les consideracions necessàries per a la seva implementació.

4.1. AI-Council Canvas

Com a punt de partida, s'ha utilitzat l'AI-Council Canvas per estructurar el problema des d'una perspectiva global i no únicament tècnica. Aquest marc permet identificar la necessitat de negoci, la decisió que es vol donar suport, el valor esperat del sistema i els principals condicionants del seu desplegament.

4.1.1. Descripció del cas d'ús

El cas d'ús analitzat en aquest projecte se centra en el desenvolupament d'un sistema intel·ligent de suport a la decisió aplicat a la gestió de reserves hoteleres. En concret, es vol donar resposta a una problemàtica especialment rellevant dins del sector: la incertesa associada a les cancel·lacions de reserves i l'impacte que aquestes tenen sobre l'ocupació final, la planificació operativa i els ingressos de l'establiment.

Per abordar aquesta situació, es planteja la construcció d'un model predictiu capaç d'estimar la probabilitat que una reserva sigui cancel·lada a partir de la informació disponible en el moment en què es realitza. Aquesta estimació no es considera com una finalitat aïllada, sinó com una peça integrada dins d'un sistema de suport a la decisió més ampli, orientat a transformar la predicció en una recomanació operativa útil per al negoci.

Així, el model no només permet identificar reserves amb un risc elevat de cancel·lació, sinó que també serveix com a punt de partida per a una capa de decisió posterior, en què aquesta informació es combina amb criteris experts i regles de negoci. Això fa possible que el sistema pugui suggerir accions concretes, com ara activar mesures preventives sobre determinades reserves, ajustar estratègies d'overbooking o reforçar el seguiment de clients amb un perfil de risc determinat.

Aquest enfocament resulta especialment adequat en un context com l'hoteler, on moltes de les decisions no depenen únicament d'una predicció estadística, sinó també del coneixement del domini, de la tolerància al risc de l'organització i de les prioritats comercials del negoci. Per aquest motiu, el projecte no s'ha plantejat únicament com un problema de classificació, sinó com el disseny d'un sistema híbrid capaç d'integrar coneixement basat en dades i coneixement expert per millorar la presa de decisions.

4.1.2. Elements del Canvas

L'AI-Council Canvas permet descriure el projecte des d'una perspectiva global, integrant tant els aspectes tècnics com els elements de negoci i organitzatius. A continuació, es presenten els principals components del Canvas adaptats al cas d'ús analitzat.

La tasca i la decisió

La tasca central del sistema consisteix a identificar quines reserves presenten un risc elevat de cancel·lació a partir de dades històriques. Aquesta predicció es basa en patrons relacionats amb el perfil del client, les característiques de la reserva i el context comercial en què aquesta s'ha realitzat.

Tanmateix, l'objectiu principal del sistema no és únicament predir, sinó millorar la presa de decisions. En concret, es pretén determinar sobre quines reserves cal aplicar accions preventives abans de la data d'arribada, contribuint així a reduir l'impacte de les cancel·lacions i a millorar la planificació de l'ocupació.

Proposta de valor

La solució aporta valor perquè permet anticipar cancel·lacions i reduir la incertesa associada a la demanda. Això es tradueix en una gestió més eficient de l'ocupació, una millor planificació dels recursos i una optimització dels ingressos. A més, el fet d'integrar el model dins d'un sistema de suport a la decisió fa possible que la predicció no es quedi només en un resultat tècnic, sinó que es transformi en una acció útil i alineada amb les necessitats operatives de l'hotel.

Judici (criteri de decisió)

El sistema es dissenya prioritzant la detecció de cancel·lacions, encara que això impliqui generar alguns falsos positius. Aquesta decisió es basa en el fet que el cost de no anticipar una cancel·lació és superior al d'aplicar una acció preventiva innecessària.

Per aquest motiu, es dona especial importància a mètriques com el recall i a la definició de llindars de risc adequats dins del sistema, de manera que la sortida del model resulti realment útil per a la presa de decisions.

Dades

El projecte es basa en un conjunt de dades històriques de reserves hoteleres que inclou informació detallada sobre les característiques de cada reserva i el seu resultat final. Aquestes dades permeten entrenar el model i identificar patrons de comportament associats a les cancel·lacions.

A més, la naturalesa i varietat de les variables disponibles fan possible construir una representació prou rica del problema. En el futur, el sistema podria ampliar-se amb fonts d'informació addicionals per millorar encara més la seva capacitat predictiva.

Resultat

L'èxit del sistema s'ha de valorar des d'una doble perspectiva. D'una banda, interessa que el model presenti un bon comportament en termes de rendiment predictiu, especialment en mètriques com el recall, atès que detectar reserves amb risc és especialment rellevant en aquest

problema. De l'altra, també cal considerar l'impacte real sobre el negoci, com ara la reducció d'habitacions buides, la millora de l'ocupació efectiva i una gestió més estable dels ingressos.

Desplegament

El sistema s'hauria d'integrar dins del gestor de reserves de l'hotel, de manera que cada nova reserva pogués ser avaluada automàticament. Això permetria incorporar la predicció dins del flux habitual de treball i facilitar una resposta més ràpida i coherent.

A més, caldria definir els llindars de risc i les accions associades en col·laboració amb els responsables de negoci, així com validar el sistema mitjançant una fase pilot abans del seu desplegament complet.

Riscos

Un dels principals riscos és la presa de decisions incorrectes a partir de prediccions errònies. En particular, una sobreestimació del risc podria conduir a estratègies d'overbooking inadequades o a l'activació de mesures preventives innecessàries.

Aquestes situacions poden generar costos operatius addicionals i afectar negativament la reputació de l'hotel, de manera que és important que el sistema sigui utilitzat com a eina de suport i no com a únic criteri de decisió.

Barreres

La implementació del sistema pot veure's limitada per factors organitzatius com la resistència al canvi o la manca de coordinació entre departaments. En un context real, l'adopció d'aquest tipus d'eines requereix una certa alineació entre les àrees implicades en la gestió de reserves.

A més, una baixa cultura de dades, la manca d'eines adequades o uns recursos tècnics limitats poden dificultar la seva adopció efectiva. Perquè el sistema tingui impacte real, no n'hi ha prou amb disposar d'un bon model: també cal que l'organització estigui preparada per incorporar-lo dins dels seus processos habituals.

AI-Council Canvas			
Projecte: Predicció de cancel·lacions en reserves hoteleres			
La tasca i la decisió Quina tasca vols analitzar? Identificar quines reserves hoteleres (City Hotel i Resort Hotel) tenen risc de ser cancel·lades. Quina decisió es pot millorar amb IA? Decidir quines reserves tenen alt risc de cancel·lació per aplicar mesures preventives abans de la data d'arribada. Quin aspecte vols millorar? Reduir l'impacte econòmic de les cancel·lacions inesperades i millorar la planificació d'ocupació i ingressos.	Proposta de Valor Quin valor proporciona una solució basada en IA? Evitar pèrdues alertant a l'hotel del risc de "No-Show". Dades Tenim accés a les dades necessàries? Sí. Disposem d'un conjunt de dades històriques de reserves hoteleres que inclou tant la informació de cada reserva com el seu resultat final (cancel·lada o no cancel·lada).	Judici (criteri de decisió) Quin preu estic disposat a pagar pels errors del sistema? S'accepta que en alguns casos es generin alertes innecessàries, ja que és més costós per al negoci no detectar una cancel·lació real que aplicar una acció preventiva que finalment no era necessària. Resultat Com podem mesurar l'èxit del projecte? Accuracy del model Recall de cancel·lacions Reducció d'habitacions buides Increment del percentatge real d'ocupació	Desplegament Què em falta per posar en marxa aquest projecte? Integrar el model al sistema de reserves Definir el llindar de risc conjuntament amb el Revenue Manager, tenint en compte l'impacte econòmic i la tolerància al risc de l'hotel. Formació del personal Pilot inicial en un dels hotels
Riscos Quins aspectes de l'organització poden posar en perill el projecte? - Overbooking fallit: Si el model prediu erròniament una cancel·lació que no es produeix - Hotel podria haver de real·lotjar clients ("walking") - Generant costos i mala reputació.	Barreres Quins aspectes de l'organització poden posar en perill el projecte? - Manca de comunicació entre els departaments de vendes i recepció. - Adopció: Hotels independents amb poca cultura de dades o recursos limitats. - Resistència a canviar els protocols actuals de gestió de reserves.		

Figura 13: AI-Council Canvas complet

4.2. Model de decisió

Un cop definit el cas d'ús i el seu context dins del Canvas, cal concretar com es transforma la informació generada pels models en una decisió útil per a l'organització. En aquest sentit, el model de decisió descriu el procés mitjançant el qual les prediccions i la informació complementària del sistema es converteixen en recomanacions operatives.

4.2.1. Descripció del procés de decisió

El procés de decisió proposat en aquest projecte es basa en la integració de diferents components dins d'un sistema de suport a la decisió (IDSS), combinant un model predictiu basat en dades amb una capa de regles de negoci i coneixement expert.

En primer lloc, per a cada nova reserva introduïda en el sistema, es recullen les variables disponibles en el moment de la seva creació (com el perfil del client, les característiques de la reserva o el canal de distribució). Aquestes dades són processades mitjançant el pipeline de preprocessament definit prèviament, garantint que la representació sigui coherent amb la utilitzada durant la fase d'entrenament.

A continuació, les dades preprocessades són introduïdes al model predictiu seleccionat (basat en XGBoost), que genera com a sortida una probabilitat associada al risc de cancel·lació de la reserva. Aquesta probabilitat constitueix el principal output del model de Machine Learning i es pot interpretar com una estimació quantitativa del risc.

De manera complementària, el sistema pot incorporar informació procedent d'un model de clustering, que permet assignar la reserva a un perfil de client determinat en funció de patrons de comportament similars observats en dades històriques. Aquest component no genera una predicció directa, sinó una descripció del tipus de client, que pot enriquir el procés de decisió.

A partir d'aquest punt, la probabilitat de cancel·lació (i, si escau, el perfil de client) no es consideren una decisió final, sinó que alimenten la capa de decisió. En aquesta segona etapa, el sistema aplica un conjunt de regles basades en llindars de risc i criteris de negoci per determinar quina acció és més adequada en cada cas.

En conjunt, el sistema queda estructurat en dues etapes complementàries: una primera etapa centrada en l'estimació del risc a partir de dades i una segona orientada a la presa de decisions. Això permet que la sortida del model no es quedi en una probabilitat aïllada, sinó que es transformi en una acció coherent amb el context operatiu de l'hotel.

4.2.2. Integració model i regles

La integració entre el model predictiu, el model de clustering i les regles de decisió constitueix el nucli del sistema IDSS.

El model predictiu rep com a entrada les variables preprocessades de la reserva i genera una probabilitat de cancel·lació com a sortida. Aquest valor és compartit amb la capa de decisió i constitueix el principal indicador de risc.

Paral·lelament, el model de clustering utilitza un subconjunt de variables rellevants per assignar la reserva a un segment o perfil de client. Aquesta informació pot ser utilitzada per modular les regles de decisió, per exemple aplicant estratègies diferenciades segons el tipus de client.

La capa de decisió combina aquests inputs mitjançant la definició de llindars sobre la probabilitat de cancel·lació. En funció del valor d'aquesta probabilitat, les reserves es classifiquen en diferents nivells de risc, com ara risc baix, risc moderat i risc alt.

En el cas de reserves amb risc baix, no es proposa cap acció addicional. Per contra, en reserves amb risc moderat es poden activar mesures preventives lleugeres, com l'enviament de recordatoris o la revisió de condicions. Finalment, en reserves amb risc alt es poden aplicar accions més intensives, com l'ajust de l'estratègia d'overbooking o la monitorització activa de la reserva.

Aquest esquema permet convertir una sortida probabilística en una decisió interpretable i accionable. A més, la interacció entre models permet enriquir la presa de decisions: el model predictiu aporta estimació de risc, mentre que el clustering aporta context sobre el comportament del client.

4.2.3. Tipus de decisions

El sistema proposat dona suport principalment a decisions de caràcter operatiu, ja que permet actuar sobre reserves individuals abans de la data d'arribada. Aquestes decisions tenen un impacte directe en la gestió diària de l'hotel i en la planificació de l'ocupació.

Tot i això, el valor del sistema no es limita a l'àmbit operatiu. L'anàlisi agregada de les prediccions i dels perfils de client també pot aportar informació útil per revisar decisions de nivell més tàctic, com ara l'ajust de polítiques comercials, la gestió dels canals de distribució o la definició de criteris d'overbooking.

En aquest sentit, el sistema opera en dos nivells complementaris. D'una banda, proporciona recomanacions específiques per a cada reserva, facilitant la presa de decisions immediates. D'altra banda, genera informació agregada que pot ser utilitzada per a la definició de polítiques a mitjà termini.

Aquesta doble dimensió reforça el valor del sistema, ja que no només permet reaccionar davant situacions concretes, sinó també aprendre del comportament global del sistema i adaptar les decisions a llarg termini.

4.2.4. Tipus d'usuaris

El sistema proposat està orientat a diversos perfils d'usuari dins del context hotelier, ja que la informació generada pot ser útil en diferents nivells de decisió.

En primer lloc, hi ha els usuaris de perfil operatiu, és a dir, el personal encarregat de la gestió diària de reserves. Per a aquest col·lectiu, el sistema pot actuar com una eina de suport en la prioritització d'accions sobre reserves concretes, especialment en aquells casos en què el risc de

cancel·lació sigui elevat. Això pot facilitar una resposta més ràpida i estructurada davant situacions que requereixen seguiment o revisió.

En segon lloc, el sistema resulta especialment rellevant per als responsables de revenue management o de planificació comercial. En aquest cas, la utilitat principal no se centra tant en la gestió individual d'una reserva, sinó en la possibilitat d'ajustar estratègies d'overbooking, revisar llimdars de risc o adaptar decisions comercials en funció dels patrons detectats pel model. Des d'aquesta perspectiva, el sistema aporta suport a decisions de caràcter més tàctic, orientades a optimitzar ocupació i ingressos.

Finalment, també es poden considerar usuaris de perfil directiu o de supervisió. Per a aquests perfils, l'interès del sistema se situa principalment en la informació agregada que pot generar, com ara tendències de cancel·lació, comportaments diferenciats segons segment de client o impacte potencial de determinades polítiques. Aquesta visió més global pot contribuir a orientar decisions de planificació i avaluar l'encaix del sistema dins dels objectius generals de l'organització.

Per tant, el sistema no s'adreça a un únic tipus d'usuari, sinó que pot donar suport a diferents perfils segons el nivell de decisió en què s'utilitzi. Aquesta diversitat reforça el seu valor dins del context hotel·ler, ja que permet combinar utilitat operativa immediata amb capacitat d'anàlisi i suport a decisions de més abast.

4.3. Arquitectura del sistema IDSS

L'arquitectura del sistema proposat s'ha dissenyat amb un enfocament modular, de manera que cada component tingui una funció clara dins del procés de suport a la decisió. L'objectiu no és només entrenar un model predictiu, sinó construir un flux complet que permeti transformar les dades d'una reserva en una recomanació operativa útil per al negoci hoteler.

Tal com es mostra a la *Figura 14*, el sistema cobreix les principals fases del cicle de vida d'un IDSS: preparació de dades, entrenament de models, segmentació de perfils, inferència sobre noves reserves, aplicació de coneixement expert i monitorització posterior dels resultats. Aquesta estructura permet separar la part analítica del sistema (basada en dades i models) de la part de decisió (basada en regles de negoci i criteris operatius), mantenint alhora una connexió clara entre totes dues.

El sistema parteix de dues fonts principals d'informació. D'una banda, la **base de dades de reserves hoteleres**, que conté les observacions històriques utilitzades per entrenar els models i analitzar el comportament de cancel·lació. D'altra banda, el **metadata** del dataset, que permet interpretar correctament les variables, identificar-ne la naturalesa i aplicar transformacions coherents durant el preprocessament.

A aquestes fonts s'hi afegeix una tercera peça fonamental: la **base de coneixement**. Aquesta no s'utilitza per entrenar el model predictiu, sinó que intervé posteriorment dins de la capa de decisió. La seva funció és recollir el coneixement expert del domini hoteler en forma de regles de negoci, llindars de risc, criteris de revenue, condicions especials i accions recomanades.




Figura 14: Arquitectura general del sistema IDSS proposat per a la predicció de cancel·lacions i la generació de recomanacions operatives.

4.3.1. Separació entre dataset del model i dataset del clustering

Un dels aspectes més importants de l'arquitectura és que el mòdul de preprocessament genera dues sortides diferenciades: el dataset del model i el dataset del clustering. Aquesta decisió respon al fet que el model predictiu i el clustering tenen objectius diferents i, per tant, no han de treballar necessàriament amb la mateixa representació de les dades.

El dataset del model està optimitzat per a la classificació supervisada. En aquest flux, les variables es transformen per obtenir una matriu numèrica compatible amb els algorismes de Machine Learning. Això inclou imputació de valors absents, escalat de variables numèriques, tractament de variables binàries i codificació one-hot de variables categòriques. Aquesta representació és adequada per entrenar el model predictiu, ja que prioritza la capacitat de predicció.

En canvi, el dataset del clustering està orientat a obtenir perfils interpretables. Per aquest motiu, s'evita aplicar clustering directament sobre la representació one-hot del model predictiu, ja que aquesta podria distorsionar les distàncies entre observacions i generar grups poc interpretables. En el seu lloc, s'utilitza una representació més compacta, amb variables seleccionades, codificacions simples i variables derivades relacionades amb l'antelació, la durada, el valor econòmic, la composició de la reserva i l'historial del client.

Aquesta separació reforça la qualitat metodològica del sistema. El model predictiu es construeix amb una representació pensada per predir cancel·lacions, mentre que el clustering es construeix amb una representació pensada per descriure perfils operatius. D'aquesta manera, cada mòdul utilitza les dades de la forma més adequada per al seu objectiu.

4.3.2. Fase d'entrenament

Durant la fase d'entrenament, el dataset del model es divideix en tres subconjunts: **train**, **validation** i **test**. Aquesta separació permet entrenar els models, ajustar-ne el comportament i avaluar-ne el rendiment final sobre dades no utilitzades durant l'entrenament.

El mòdul d'**entrenament de models** utilitza aquests conjunts per comparar diferents algorismes de classificació i seleccionar el model final. En la versió final del sistema, el model seleccionat és **XGBoost**, ja que ofereix el millor equilibri entre F1-score, recall i capacitat discriminativa. El resultat d'aquesta fase és el **model final entrenat**, que queda preparat per utilitzar-se posteriorment en producció.

En paral·lel, el **dataset del clustering** alimenta el mòdul de clustering. Aquest mòdul identifica patrons de comportament similars entre reserves i genera els **perfils operatius** que posteriorment s'utilitzen dins la capa de decisió. Aquests perfils no substitueixen la predicció del model, sinó que aporten context sobre el tipus de reserva: per exemple, si es tracta d'una reserva anticipada, d'última hora, premium, familiar, estàndard o corporativa.

Aquesta fase d'entrenament, per tant, produeix dos resultats complementaris: un model predictiu capaç d'estimar el risc de cancel·lació i un conjunt de perfils que ajuden a interpretar millor el context de cada reserva.

4.3.3. Fase de producció i inferència

Un cop entrenats els components principals, el sistema pot aplicar-se a noves reserves. En la fase de **producció o inferència**, el sistema rep les dades d'una nova reserva i les processa per generar una estimació de risc.

La nova reserva és transformada mitjançant el mateix criteri utilitzat durant el desenvolupament del sistema. Això implica generar les variables derivades necessàries, aplicar el preprocessament corresponent i assegurar que la informació introduïda sigui compatible amb el model final entrenat. A continuació, el model XGBoost calcula el **score de cancel·lació**, expressat com una probabilitat.

Aquest score no es considera una decisió final. La probabilitat de cancel·lació és només un indicador quantitatiu de risc que necessita ser interpretat dins del context de negoci. Per això, el sistema combina aquesta probabilitat amb el perfil operatiu de la reserva i amb la base de coneixement. Aquesta combinació es realitza dins la **capa de decisió IDSS**, que constitueix el nucli del sistema. Aquesta capa rep tres entrades principals:

Entrada	Funció dins la capa de decisió
Score de cancel·lació	Indica el risc estimat pel model predictiu
Perfil operatiu	Aporta context sobre el tipus de reserva o client
Base de coneixement	Defineix regles de negoci, l·lindars i accions recomanades

Taula 2. Entrades i les seves funcions al IDSS

A partir d'aquestes entrades, la capa de decisió aplica les regles definides i genera una **recomanació final**. Aquesta recomanació pot consistir en una comunicació automàtica, una confirmació activa, una trucada, una revisió manual, una validació de garantia, una intervenció de revenue management o una altra acció operativa coherent amb el risc detectat.

4.3.4. Capa de decisió IDSS

La capa de decisió és l'element que diferencia el sistema d'un model predictiu convencional. Sense aquesta capa, el sistema només retornaria una probabilitat de cancel·lació. Amb la capa IDSS, aquesta probabilitat es transforma en una acció concreta i interpretable.

Aquesta capa combina coneixement basat en dades i coneixement expert. El coneixement basat en dades prové del model predictiu i del clustering. El coneixement expert prové de la base de coneixement, on es defineixen els l·lindars de risc, els perfils operatius, les regles específiques per perfil i les regles globals aplicables a totes les reserves.

Això permet que el sistema adapti la recomanació a cada cas. Per exemple, una reserva amb risc alt i valor econòmic elevat pot justificar una intervenció personalitzada, mentre que una reserva de baix valor amb risc similar pot gestionar-se amb canals automàtics. De la mateixa manera,

una reserva familiar pot requerir confirmació de serveis i logística, mentre que una reserva corporativa pot necessitar revisió de condicions comercials abans d'aplicar mesures restrictives.

Des d'una perspectiva de negoci, aquesta capa és essencial perquè evita accions uniformes i poc eficients. El sistema no tracta totes les reserves d'alt risc igual, sinó que prioritza els recursos segons el valor de la reserva, el perfil, el nivell de risc i el cost de la intervenció.

4.3.5. Monitorització i feedback

L'arquitectura incorpora també un mòdul de **monitorització i feedback**, que tanca el cicle del sistema. Un cop es coneix el resultat real de la reserva, és a dir, si finalment s'ha cancel·lat o s'ha completat, aquesta informació es recull i es compara amb la predicció generada pel model.

Aquest mòdul compleix diverses funcions. En primer lloc, permet avaluar si el model manté un rendiment adequat al llarg del temps. En segon lloc, ajuda a detectar possibles canvis en el comportament dels clients o en les condicions del mercat. En tercer lloc, proporciona informació útil per decidir quan és necessari reentrenar el model o revisar les regles de negoci.

La monitorització també permet analitzar l'efectivitat de les recomanacions generades. Per exemple, es podria estudiar si les reserves sobre les quals s'ha aplicat una acció preventiva han reduït la seva taxa de cancel·lació o si determinades accions són més efectives per a uns perfils que per a uns altres. Això obre la porta a una millora contínua del sistema.

En el marc del projecte, aquest procés es planteja com un feedback offline i periòdic. Això significa que el sistema no aprèn automàticament de cada nova reserva en temps real, sinó que acumula resultats, els revisa i permet actualitzar el model i les regles en futures iteracions.

4.3.6. Components del sistema

Els principals components de l'arquitectura es poden resumir de la manera següent:

Component	Funció principal
Base de dades	Conté les reserves històriques i les noves reserves a analitzar
Metadata	Ajuda a interpretar variables, tipus de dades i transformacions necessàries
Preprocessament	Genera representacions adequades per al model i per al clustering
Dataset model	Matriu preparada per a l'entrenament del model predictiu
Dataset clustering	Matriu compacta i interpretable per obtenir perfils operatius
Entrenament de models	Construeix i selecciona el model predictiu final
Model final entrenat	Estima la probabilitat de cancel·lació d'una reserva
Clustering	Identifica perfils de reserva o client a partir de patrons similars

Producció/inferència	Aplica el model entrenat a noves reserves
Base de coneixement	Recull regles expertes i criteris de decisió
Capa de decisió IDSS	Combina score, perfil i regles per generar una recomanació
Monitorització i feedback	Compara prediccions amb resultats reals i facilita el reentrenament

Taula 3. Components del sistema

Aquesta estructura modular facilita el manteniment del sistema. Si es vol millorar el model predictiu, es pot treballar sobre el mòdul d'entrenament sense modificar la base de coneixement. Si es vol ajustar la política comercial, es poden modificar les regles sense reentrenar el model. I si es vol revisar el perfilat, es pot actualitzar el clustering sense alterar necessàriament el conjunt del sistema.

4.3.7. Flux d'informació

El flux d'informació del sistema es pot dividir en tres grans moments: entrenament, inferència i monitorització.

Durant l'**entrenament**, les dades històriques i el metadata passen pel mòdul de preprocessament. Aquest mòdul genera el dataset del model i el dataset del clustering. El primer es divideix en train, validation i test i s'utilitza per entrenar i seleccionar el model predictiu final. El segon alimenta el mòdul de clustering i permet obtenir els perfils operatius.

Durant la **inferència**, el sistema rep una nova reserva. Aquesta reserva es processa, s'introdueix al model final entrenat i genera un score de cancel·lació. El score, juntament amb el perfil operatiu i la base de coneixement, entra a la capa de decisió IDSS. Aquesta capa aplica les regles de negoci i produeix la recomanació final.

Finalment, durant la **monitorització**, el sistema incorpora les dades del resultat real de la reserva. Aquesta informació permet comparar el que el sistema havia estimat amb el que realment ha passat. A partir d'aquesta comparació, es pot valorar el rendiment del model, revisar la utilitat de les recomanacions i decidir si cal actualitzar el sistema.

Aquest flux permet que el sistema sigui cíclic i millorable. No es tracta d'un model estàtic, sinó d'una arquitectura que pot adaptar-se progressivament a mesura que es disposa de noves dades i de més experiència operativa.

4.4. Consideracions d'implementació

Més enllà del disseny conceptual del sistema, és necessari considerar quins requisits hauria de complir perquè pogués funcionar en un context d'ús real o simulat. Per aquest motiu, en aquest apartat es recullen alguns aspectes pràctics relacionats amb les dades necessàries, el seu tractament en producció i la manera com es planteja el manteniment posterior del sistema.

4.4.1. Requisits de dades i transformacions en producció

Per tal que el sistema pugui funcionar en un entorn de producció, és necessari disposar de les mateixes variables d'entrada que s'han utilitzat en la fase d'entrenament, o bé d'un conjunt equivalent que permeti reproduir la representació final de les dades. Això implica que cada nova reserva ha de contenir informació suficient sobre les característiques de la reserva, el perfil del client i el context comercial en què s'ha realitzat.

Aquestes dades no poden ser introduïdes directament al model en format brut, sinó que han de passar pel mateix pipeline de preprocessament utilitzat durant l'entrenament. Aquest requisit és clau per garantir la coherència entre la fase de desenvolupament i la fase d'inferència. En aquest sentit, el preprocessador desat actua com una peça central del sistema, ja que permet aplicar de manera automàtica les mateixes imputacions, transformacions i codificacions a noves dades.

A més, cal tenir en compte que algunes variables derivades, com ara *total_nights*, *total_guests*, *adr_per_guest* o *country_risk*, s'han de generar també en el moment de la inferència. Per tant, el sistema no només ha de rebre dades, sinó que ha d'incorporar els mecanismes necessaris per transformar-les correctament abans de fer la predicció.

4.4.2. Accés a dades i permisos

En un escenari real, el sistema hauria de disposar d'accés a la base de dades de reserves o al sistema de gestió hotelera des d'on es registren les noves reserves. Aquest accés hauria de permetre llegir les variables necessàries en el moment de la creació de la reserva, així com recuperar posteriorment el resultat final de la mateixa per alimentar el mòdul de monitorització.

A nivell operatiu, això implicaria disposar de permisos de lectura sobre les dades de reserva i, eventualment, accés a la informació relacionada amb l'estat final de cada cas.

En el context d'aquest projecte, però, no s'ha treballat amb un sistema en producció real, sinó amb un conjunt de dades exportat en format CSV. Per aquest motiu, no ha estat necessari gestionar connexions en temps real ni permisos sobre sistemes externs.

4.4.3. Eines de software utilitzades

En el desenvolupament del projecte s'han utilitzat diferents eines de programari orientades al tractament, anàlisi i modelització de dades. La part principal del treball s'ha dut a terme en Python, fent servir llibreries especialitzades en manipulació de dades, càlcul numèric, visualització i aprenentatge automàtic. També s'han utilitzat notebooks per a l'anàlisi

exploratòria i la validació iterativa de decisions de preprocessament, així com eines de persistència de models i exportació de resultats per facilitar la seva reutilització en les diferents fases del sistema. De manera complementària, s'han utilitzat aplicacions d'edició de documents i presentacions per a la redacció del report i de la presentació per la comunicació dels resultats obtinguts.

5. Models predictius de cancel·lació

En aquesta secció es descriu el procés de modelització supervisada utilitzat per estimar el risc de cancel·lació de les reserves hoteleres. L'objectiu d'aquesta fase no ha estat únicament entrenar un classificador amb bon rendiment, sinó seleccionar un model capaç de generar una probabilitat de cancel·lació útil per alimentar posteriorment la capa de decisió del sistema IDSS.

Per aquest motiu, s'han comparat diferents famílies d'algorismes de classificació, des de models simples i interpretables fins a models més flexibles basats en arbres i tècniques d'ensemble. Aquesta comparació ha permès valorar no només el rendiment predictiu, sinó també l'equilibri entre sensibilitat, precisió, capacitat discriminativa i adequació al context de negoci.

Tots els models s'han entrenat a partir del conjunt de dades preprocessat descrit en l'apartat anterior. La representació final utilitzada pel model predictiu conté 65 variables processades, resultat de combinar variables numèriques escalades, variables binàries i variables categòriques codificades mitjançant one-hot encoding. La partició de les dades s'ha mantingut separada en subconjunts d'entrenament, validació i test, amb una divisió estratificada per conservar una proporció similar de reserves cancel·lades i no cancel·lades en tots els conjunts.

La mètrica principal utilitzada per comparar els models ha estat l'F1-score, ja que combina precision i recall en una única mesura. Aquesta elecció és coherent amb el cas d'ús, perquè el sistema ha de detectar el màxim nombre possible de reserves amb risc de cancel·lació, però sense generar un volum excessiu de falses alarmes. A més, també s'han considerat altres mètriques complementàries, com l'accuracy, la precision, el recall i l'AUC, per obtenir una visió més completa del comportament de cada model.

5.1. Estratègia de modelització

La modelització s'ha organitzat en dues fases. En primer lloc, s'han entrenat models de referència i classificadors relativament simples, amb configuracions fixades manualment. Aquesta etapa ha permès establir una línia base sòlida i comprovar fins a quin punt models lineals o probabilístics eren capaços de capturar els patrons del conjunt de dades.

En segon lloc, s'han avaluat models més avançats basats en arbres i ensemble learning, aplicant validació creuada i cerca aleatòria d'hiperparàmetres. Aquesta segona fase tenia com a objectiu millorar el rendiment obtingut pels models base i explorar algorismes més adequats per capturar relacions no lineals i interaccions entre variables.

Aquesta estratègia progressiva permet justificar millor la selecció final del model. D'aquesta manera, no es parteix directament d'un algorisme complex, sinó que es compara el seu rendiment amb alternatives més simples i interpretables.

5.2. Models de referència i models base

En una primera fase s'han avaluat diversos models de referència i classificadors de complexitat moderada: Dummy Classifier, Logistic Regression, Logistic Regression amb regularització L1, Linear SVC, SGD Classifier, Decision Tree i Gaussian Naive Bayes.

El **Dummy Classifier**, configurat amb l'estratègia `most_frequent`, s'ha utilitzat com a línia base mínima. Aquest model prediu sempre la classe majoritària i, per tant, no aprèn cap patró real de les dades. Els seus resultats confirmen que el problema requereix models capaços d'explotar la informació continguda en les variables, ja que obté una F1 igual a 0 i una AUC de 0,5.

La **Logistic Regression** s'ha entrenat com a model lineal interpretable. S'ha utilitzat `class_weight="balanced"` per compensar el desequilibri moderat entre classes i evitar que el model tendeixi excessivament cap a la classe majoritària. Aquest model ha proporcionat una base competitiva, amb un bon equilibri entre precision i recall. També s'ha avaluat una variant amb regularització L1, que introdueix selecció implícita de variables i permet comprovar si una representació més esparsa millora la generalització. Els resultats d'ambdues versions han estat molt similars, fet que indica que els models lineals ja capturen una part rellevant del patró de cancel·lació.

El **Linear SVC** també ha mostrat un rendiment sòlid dins del grup de models base. Aquest model és especialment adequat per espais de variables d'alta dimensionalitat, com els generats després de la codificació de variables categòriques. Tot i que no proporciona probabilitats de manera directa, ha obtingut uns resultats molt propers als de la regressió logística i ha actuat com una alternativa lineal robusta.

També s'ha provat **SGD Classifier amb funció de pèrdua logística**. Aquest model ofereix una aproximació lineal entrenada de manera iterativa i pot ser útil en escenaris amb moltes dades o quan es busca una alternativa computacionalment lleugera. En aquest cas, però, el seu rendiment ha quedat per sota dels millors models lineals.

L'**arbre de decisió** (Decision Tree) s'ha inclòs com a primer model no lineal. Aquest algorisme permet capturar interaccions entre variables i ofereix una interpretació relativament senzilla en forma de regles. Tot i això, el seu rendiment no ha superat el dels millors models lineals, fet que suggereix que un únic arbre no és suficient per representar de manera estable la complexitat del problema.

Finalment, s'ha avaluat **Gaussian Naive Bayes**, un model probabilístic simple basat en la hipòtesi d'independència condicional entre variables. Aquesta hipòtesi és poc realista en aquest cas, ja que moltes variables de reserva estan relacionades entre si. El model ha obtingut un recall molt elevat, però a costa d'una accuracy i una F1 clarament inferiors. Això indica una tendència a sobrepredir la classe de cancel·lació, generant massa falsos positius.

En conjunt, aquesta primera fase mostra que els models lineals regularitzats ofereixen una base estable i competitiva. Tanmateix, els resultats també suggereixen que el problema pot beneficiar-se de models capaços de capturar relacions no lineals i interaccions més complexes entre variables.

5.3. Models avançats basats en arbres i ensemble learning

En una segona fase s'han avaluat models més potents basats en arbres de decisió i tècniques d'ensemble: Random Forest, Extra Trees, HistGradientBoosting i XGBoost.

A diferència de la fase inicial, aquests models s'han ajustat mitjançant validació creuada estratificada i RandomizedSearchCV. Per fer aquesta cerca, s'ha utilitzat el conjunt de desenvolupament format per la unió dels subconjunts d'entrenament i validació, mentre que el conjunt de test s'ha mantingut completament separat per a l'avaluació final. Aquesta estratègia permet aprofitar més dades durant l'ajust d'hiperparàmetres sense comprometre la independència del test final.

El model **Random Forest** combina múltiples arbres de decisió entrenats sobre mostres diferents del conjunt de dades. Aquesta tècnica redueix la variància respecte a un únic arbre i acostuma a oferir un comportament més estable. En aquest cas, la millor configuració trobada ha estat basada en 300 arbres, profunditat màxima de 8 i restriccions sobre el nombre mínim de mostres per divisió i per fulla. El model ha obtingut una F1 de 0,7767 i una AUC de 0,9209 en test, millorant clarament els models base.

El model **Extra Trees** també utilitza un conjunt d'arbres, però introdueix més aleatorietat en la selecció dels punts de tall. Aquesta característica pot reduir el sobreajust en alguns escenaris, tot i que també pot generar models menys ajustats a patrons específics de les dades. En aquest projecte, Extra Trees ha obtingut un recall elevat, de 0,8716, però una F1 lleugerament inferior a Random Forest i XGBoost. Això indica que detecta moltes cancel·lacions, però amb un equilibri una mica menys favorable entre precision i recall.

El model **HistGradientBoosting** s'ha inclòs com a alternativa de boosting eficient. Aquest algorisme construeix arbres de manera seqüencial, corregint progressivament els errors dels models anteriors. Ha obtingut una accuracy elevada i una AUC competitiva, però el seu recall ha estat inferior al d'altres models avançats. En el context del projecte, aquesta limitació és rellevant, ja que detectar reserves amb risc de cancel·lació és una prioritat del sistema.

Finalment, s'ha avaluat **XGBoost**, també basat en gradient boosting, però amb mecanismes addicionals de regularització i control de la complexitat. S'ha utilitzat una formulació específica per a classificació binària (binary:logistic) i s'ha ajustat el desequilibri de classes mitjançant scale_pos_weight. La millor configuració obtinguda ha estat:

```
n_estimators = 200
max_depth = 5
learning_rate = 0.03
subsample = 0.8
colsample_bytree = 0.85
min_child_weight = 1
```

Aquest model ha estat el que ha mostrat el millor comportament global. En el conjunt de test, XGBoost ha assolit una accuracy de 0,8404, una precision de 0,7383, un recall de 0,8507, una F1 de 0,7906 i una AUC de 0,9241. Aquests resultats indiquen que el model combina una bona capacitat per detectar cancel·lacions amb una proporció raonable de falsos positius.

5.4. Comparació dels resultats

Model	Accuracy	Recall	F1	AUC
Dummy Most Frequent	0.6459	0.0000	0.0000	0.5000
Gaussian NB	0.4641	0.9761	0.5633	0.7866
SGD Classifier	0.7727	0.8179	0.7182	0.8625
Decision Tree	0.8002	0.8328	0.7470	0.8798
Logistic Regression L1	0.8034	0.8269	0.7486	0.8886
Logistic Regression	0.8055	0.8269	0.7507	0.8885
Linear SVC	0.8055	0.8269	0.7507	0.8876
Extra Trees	0.8171	0.8716	0.7715	0.9174
HistGradientBoosting	0.8383	0.7373	0.7635	0.9221
Random Forest	0.8340	0.8149	0.7767	0.9209
XGBoost	0,8404	0,8507	0,7906	0,9241

Taula 4. Comparativa del rendiment dels models predictius avaluats sobre el conjunt de test mitjançant les mètriques accuracy, recall, F1 i AUC.

Els resultats mostren una millora clara dels models avançats respecte als models base. Els models lineals, especialment Logistic Regression i Linear SVC, ofereixen una base sòlida, amb una F1 al voltant de 0,75 i una AUC propera a 0,89. No obstant això, els models basats en arbres aconseguixen una capacitat discriminativa superior.

Entre els models avançats, XGBoost és el que presenta el millor equilibri global. HistGradientBoosting aconseguix una AUC elevada, però el seu recall és inferior, fet que implica que deixa escapar més reserves cancel·lades. Extra Trees presenta un recall molt alt, però una F1 inferior a XGBoost, la qual cosa indica un pitjor equilibri entre detecció de cancel·lacions i precisió de les alertes generades.

Random Forest també mostra un rendiment competitiu, però queda lleugerament per sota de XGBoost tant en F1 com en AUC. Per tant, XGBoost és el model que ofereix la millor combinació entre capacitat discriminativa, detecció de cancel·lacions i control dels falsos positius.

5.5. Selecció del model final

A partir dels resultats obtinguts, s'ha seleccionat **XGBoost** com a model final del sistema. Aquesta decisió es justifica principalment perquè és el model amb millor F1 en el conjunt de test i, alhora, manté un recall elevat i una AUC molt competitiva.

La selecció d'aquest model és coherent amb els objectius del projecte. En un sistema de suport a la decisió per a la gestió de cancel·lacions hoteleres, el cost de no detectar una reserva amb alta probabilitat de cancel·lació pot ser superior al cost d'activar una acció preventiva sobre una reserva que finalment no es cancel·la. Per aquest motiu, el recall és una mètrica especialment important. Tanmateix, també cal evitar que el sistema generi massa falsos positius, ja que això podria derivar en accions comercials innecessàries o en una càrrega operativa excessiva. L'F1-score permet equilibrar aquests dos aspectes.

XGBoost ofereix aquest equilibri de manera més sòlida que la resta de models. Amb una F1 de **0,7906**, un recall de **0,8507** i una AUC de **0,9241**, el model mostra una bona capacitat per detectar reserves cancel·lades i, al mateix temps, manté una capacitat discriminativa elevada. A més, la seva precision de **0,7383** indica que una proporció important de les reserves assenyalades com a risc corresponen realment a cancel·lacions, fet que redueix el cost operatiu de les alertes generades.

Un altre avantatge rellevant és que XGBoost pot generar probabilitats de cancel·lació, no només etiquetes de classe. Això és fonamental dins del sistema IDSS, ja que la probabilitat estimada s'utilitza posteriorment com a input de la capa de decisió. D'aquesta manera, el model no actua com un classificador tancat, sinó com un generador d'un indicador quantitatiu de risc que pot combinar-se amb regles de negoci, perfils de client i criteris operatius.

5.6. Interpretabilitat del model amb SHAP

Un cop seleccionat el model final, s'ha incorporat una anàlisi d'interpretabilitat mitjançant SHAP. Aquesta tècnica permet estimar la contribució de cada variable a les prediccions del model, tant a nivell global com a nivell individual.

A nivell global, SHAP permet identificar quines variables tenen més pes en el comportament general del model. Els resultats obtinguts mostren que les variables més influents són `country_risk_Low`, `lead_time`, `market_segment_Online TA`, `total_of_special_requests`, `country_risk_High`, `previous_cancellations`, `customer_type_Transient`, `required_car_parking_spaces`, `adr` i `market_segment_Groups`.




Figura 15: Importància global de les variables segons els valors SHAP del model XGBoost

La rellevància de `lead_time` és coherent amb l'anàlisi exploratòria prèvia, on ja s'havia observat que les reserves fetes amb més antelació presentaven una major probabilitat de cancel·lació. També destaca el pes de `country_risk`, tant en la seva categoria de risc baix com en la de risc alt. Això indica que l'agrupació del país d'origen en nivells de risc ha aportat informació útil al model i ha permès conservar informació contextual sense introduir una fragmentació excessiva de categories.

Les variables relacionades amb el canal comercial, com `market_segment_Online TA` i `market_segment_Groups`, també tenen una contribució important. Aquest resultat és coherent amb l'EDA, on ja s'havien observat diferències en la taxa de cancel·lació segons el segment de mercat. De la mateixa manera, `previous_cancellations` aporta informació sobre l'historial del client, mentre que `total_of_special_requests` pot actuar com un senyal d'implicació amb l'estada.

També apareixen variables com `adr` i `required_car_parking_spaces`. En el cas d' `adr`, la seva importància suggereix que el valor econòmic de la reserva pot contribuir a modular el risc, encara que no sigui l'únic factor determinant. En el cas de `required_car_parking_spaces`, la seva presència pot interpretar-se com un senyal de concreció del viatge, tot i que s'ha de llegir amb prudència perquè és una variable amb poca variabilitat.

A nivell individual, SHAP permet explicar per què una reserva concreta rep una probabilitat elevada o baixa de cancel·lació. Aquesta característica és especialment rellevant en el context d'un IDSS, ja que facilita que l'usuari no només vegi una puntuació de risc, sinó també una justificació dels factors que han contribuït a aquesta estimació.

Cal remarcar, però, que els valors SHAP expliquen el comportament intern del model i no impliquen causalitat. Per tant, no s'ha d'interpretar que una variable "causa" directament la cancel·lació, sinó que ha contribuït a la predicció generada pel model. Tot i aquesta limitació, SHAP és útil per augmentar la transparència del sistema i per orientar la interpretació de les prediccions dins de la capa de decisió.




Figura 16: Distribució de l'impacte de les variables sobre la predicció de cancel·lació segons SHAP.

6. Clustering

L'anàlisi de clustering s'ha incorporat al projecte com un component complementari al model predictiu de cancel·lació. El seu objectiu no és predir directament si una reserva serà cancel·lada, sinó identificar grups de reserves amb característiques similars que puguin ser interpretats com a perfils operatius. D'aquesta manera, el clustering aporta context a la probabilitat generada pel model supervisat i permet que la capa de decisió adapti les recomanacions segons el tipus de reserva.

Aquesta distinció és important dins del sistema IDSS. El model predictiu estima el risc de cancel·lació, mentre que el clustering ajuda a entendre quin tipus de reserva s'està analitzant. Per exemple, dues reserves poden tenir una probabilitat de cancel·lació semblant, però requerir actuacions diferents si una correspon a una família, una altra a una reserva d'última hora i una altra a una reserva premium. Per tant, el valor del clustering no es troba en substituir el model supervisat, sinó en enriquir la presa de decisions amb una lectura descriptiva i operativa del comportament de les reserves.

6.1. Primera aproximació al clustering i limitacions detectades

En una primera aproximació, el clustering es va aplicar directament sobre el conjunt de dades preprocessat que s'havia utilitzat per entrenar els models predictius. Aquesta matriu contenia 63 variables, incloent variables numèriques escalades, variables binàries i variables categòriques codificades mitjançant one-hot encoding.

Sobre aquesta representació es van provar dos enfocaments principals: **K-means**, com a mètode particional de referència, i **HDBSCAN**, com a mètode basat en densitat capaç d'identificar soroll i estructures irregulars. La variable objectiu `is_canceled` no es va utilitzar per construir els clústers, sinó únicament per interpretar posteriorment si els grups obtinguts presentaven diferències en la taxa de cancel·lació.

Els resultats inicials, però, no van ser satisfactoris. En el cas de K-means, es van provar diversos valors de k , però les mètriques internes indicaven una separació feble entre grups. Els valors de silhouette es mantenien baixos, aproximadament entre 0,08 i 0,11, fet que indicava que els clústers no eren compactes ni clarament separables. A més, quan es va analitzar la solució amb $k = 2$, les taxes de cancel·lació dels dos grups eren molt similars, al voltant del 36,3% i del 34,8%. Aquesta diferència era massa petita per justificar una segmentació útil des del punt de vista del negoci.




Figura 17: Corba elbow de K-means: la inèrcia disminueix sense mostrar un colze clar




Figura 18: Resultat del clustering amb K-means (K=2) i visualitzat amb PCA.

HDBSCAN tampoc va proporcionar una estructura aprofitable. Tot i que el mètode permet detectar punts de soroll i no força totes les observacions a pertànyer a un clúster, en aquest cas la majoria de reserves quedaven concentrades en un únic grup majoritari. Això impedia construir perfils diferenciats i, per tant, limitava la seva utilitat com a base per a regles de negoci específiques.

La conclusió d'aquesta primera fase va ser que el problema no es trobava únicament en l'algorisme utilitzat, sinó sobretot en la representació de les dades. El dataset preprocessat per al model supervisat era adequat per maximitzar la capacitat predictiva, però no per obtenir grups interpretables.




Figura 19: Resultat del clustering amb HDBSCAN i visualitzat amb PCA.

La conclusió d'aquesta primera fase va ser que el problema no es trobava únicament en l'algorisme utilitzat, sinó sobretot en la representació de les dades. El dataset preprocessat per al model supervisat era adequat per maximitzar la capacitat predictiva, però no per obtenir grups interpretables.

6.2. Errors metodològics de la primera versió

La primera versió del clustering presentava diverses limitacions metodològiques que expliquen la baixa qualitat dels resultats obtinguts.

En primer lloc, s'havia utilitzat el mateix preprocessament que per al model predictiu. Aquesta decisió no era adequada perquè el clustering i la classificació supervisada tenen objectius diferents. El model predictiu pot beneficiar-se d'una representació d'alta dimensionalitat amb moltes variables one-hot, mentre que el clustering depèn directament de les distàncies entre observacions. Quan hi ha moltes columnes binàries derivades de variables categòriques, aquestes distàncies poden quedar distorsionades i els grups poden reflectir més la codificació que no pas patrons reals de comportament.

En segon lloc, algunes variables categòriques quedaven representades per moltes columnes separades, fet que podia donar un pes excessiu a determinades modalitats. Això podia provocar que els clústers quedessin definits per categories concretes, en lloc de reflectir perfils operatius més generals.

En tercer lloc, la representació inicial incloïa variables temporals massa específiques, com `arrival_date_year`, `arrival_date_week_number` o `arrival_date_day_of_month`. Aquestes variables poden tenir certa utilitat en un model predictiu, però per al clustering introdueixen soroll i dificulten la identificació de perfils estables. Per exemple, el dia exacte del mes o el número de setmana poden generar separacions artificials que no tenen una interpretació clara com a perfil de reserva.

Finalment, en la primera versió es va donar massa pes a les mètriques internes i no prou a la interpretabilitat dels segments. En el context d'un IDSS, un clúster només és útil si es pot traduir en un perfil comprensible i en una possible orientació operativa. Per tant, no n'hi ha prou amb obtenir una partició matemàticament acceptable: cal que els grups tinguin sentit des del punt de vista del negoci hotelier. Aquestes limitacions van motivar un replantejament complet del clustering.

6.3. Replantejament del clustering

En la versió final, el clustering s'ha construït a partir d'un dataset específic, diferent del dataset utilitzat per al model predictiu. Aquesta decisió permet separar clarament els objectius de cada component: el model supervisat busca predir cancel·lacions amb el màxim rendiment possible, mentre que el clustering busca obtenir perfils compactes, interpretables i útils per modular les recomanacions del sistema.

La nova representació evita l'ús de one-hot encoding i es basa en una selecció de variables més compacta, agrupada en cinc dimensions operatives:

Dimensió	Variables utilitzades
Planificació	lead_time
Estada	total_nights, total_guests, is_family_booking
Valor econòmic	adr_per_guest, spend_total
Comportament del client	previous_cancellations, has_agent, is_repeated_guest, booking_complexity, total_of_special_requests
Canal i context	is_resort, meal_enc, segment_enc, customer_type_enc, country_risk_enc

Taula 5. Variables seleccionades pel clustering

Aquesta selecció permet descriure les reserves no només pel seu risc de cancel·lació, sinó també per característiques rellevants per a la gestió hotelera: antelació, durada, valor econòmic, composició del grup, historial del client i canal comercial. Aquesta estructura coincideix amb la lògica del notebook actual, on el clustering es construeix a partir de variables de planificació, estada, valor econòmic, comportament i canal/context.

Les variables categòriques s'han codificat mitjançant mapatges numèrics compactes. Per exemple, `hotel` s'ha transformat en `is_resort`, indicant si la reserva correspon a un hotel tipus resort. Altres variables com `meal`, `market_segment`, `customer_type` i `country_risk` s'han codificat amb valors numèrics simples. Aquesta estratègia conserva informació rellevant sense augmentar artificialment la dimensionalitat de l'espai.

També s'han generat dues variables derivades específiques per al perfilat. La variable `spend_total` aproxima el valor econòmic total de la reserva a partir de l'ADR per hoste, el nombre d'hostes i la durada de l'estada. Aquesta variable és útil perquè permet diferenciar reserves amb impacte econòmic diferent, encara que tinguin característiques similars en altres dimensions. La variable `booking_complexity` resumeix la complexitat operativa de la reserva, combinant la presència de peticions especials i el fet que es tracti d'una reserva familiar.

Abans d'aplicar els models de clustering, totes les variables s'han imputat quan era necessari i s'han estandarditzat amb `StandardScaler`. Aquesta etapa és imprescindible perquè els mètodes utilitzats es basen en distàncies i, per tant, són sensibles a les diferències d'escala entre variables.

Abans de seleccionar el model final de clustering, s'ha aplicat PCA com a eina de diagnòstic i visualització. L'objectiu del PCA no és substituir la matriu completa de clustering, sinó obtenir una projecció en dues o tres dimensions que permeti observar visualment l'estructura general de les dades.

Les dues primeres components principals expliquen aproximadament entre el 35% i el 40% de la variància total, mentre que les tres primeres components s'aproximen al 50%. Això indica que l'espai de clustering és multidimensional i que una representació en dues dimensions és necessàriament una simplificació. Tot i així, aquesta projecció resulta útil per comparar visualment les solucions de clustering i detectar si els grups obtinguts presenten una separació mínima.




Figura 20: Variància explicada acumulada per PCA.

Aquesta anàlisi també ajuda a evitar una interpretació massa forta dels gràfics en 2D. Si els clústers no apareixen perfectament separats en el pla PCA, això no implica necessàriament que no existeixi estructura en l'espai complet. Per aquest motiu, la selecció final no s'ha basat únicament en la visualització, sinó també en mètriques internes i en la interpretabilitat dels perfils.

6.4. Selecció del nombre de clústers i comparació de models

Per seleccionar el nombre de clústers, s'han avaluat diferents valors de K, entre 2 i 8. Per a cada valor s'han calculat quatre mètriques internes: inèrcia, *silhouette*, índex de Davies-Bouldin i índex de Calinski-Harabasz.

La inèrcia s'ha utilitzat com a suport visual per analitzar si existia un punt de colze. La mètrica *silhouette* s'ha considerat el criteri principal, ja que combina cohesió interna i separació entre grups. L'índex de Davies-Bouldin s'ha utilitzat com a mesura complementària, buscant valors més baixos, mentre que l'índex de Calinski-Harabasz s'ha considerat com un indicador addicional de separació global.




Figura 21: Avaluació del nombre de clústers segons inèrcia, *silhouette*, Davies-Bouldin i Calinski-Harabasz.

La selecció final del nombre de clústers no s'ha fet només amb criteris numèrics. També s'ha tingut en compte la interpretabilitat dels perfils resultants. Aquesta decisió és coherent amb l'objectiu del projecte: dins d'un IDSS, el clustering no ha de produir únicament grups estadísticament diferenciats, sinó perfils que puguin ser entesos i utilitzats per la capa de decisió. Un cop fixat el nombre de clústers, s'han comparat tres models:

- K-means: Model particional de referència, útil per obtenir grups compactes i centroides interpretables.
- Clustering jeràrquic Ward: Alternativa per analitzar si existeix una estructura jeràrquica entre reserves.
- Gaussian Mixture Model: Model probabilístic capaç de representar grups amb formes més flexibles.




Figura 22: Comparació visual dels tres models en el pla PCA 2D, amb la puntuació *silhouette* de cada un.

El model final s'ha seleccionat combinant el valor de *silhouette* amb la coherència interpretativa dels grups. Aquesta combinació evita escollir una solució que sigui bona només des del punt de vista numèric però poc útil per al negoci.

6.5. Interpretació dels perfils obtinguts

Un cop assignada cada reserva a un clúster, s'ha dut a terme una anàlisi descriptiva dels grups obtinguts amb l'objectiu de transformar una partició numèrica en perfils operatius interpretables. Aquesta etapa és especialment important perquè, dins del sistema IDSS, els clústers no s'utilitzen com a resultat final, sinó com a informació contextual per adaptar les recomanacions de negoci.

Per interpretar els clústers, no s'ha tingut en compte únicament una variable concreta, sinó una combinació de diferents dimensions de la reserva. D'una banda, s'han analitzat variables quantitatives, com l'antelació, la durada de l'estada, el nombre d'hostes, el preu per hoste, la despesa total o el nombre de peticions especials. D'altra banda, aquesta lectura s'ha complementat amb variables binàries i categòriques, com la presència de reserva familiar, l'existència de cancel·lacions prèvies, la recurrència del client, el segment de mercat, el canal de distribució i el risc associat al país d'origen.

A partir d'aquesta anàlisi, cada clúster s'ha associat a una etiqueta de perfil operatiu. Aquestes etiquetes no són classes supervisades ni indiquen directament si una reserva es cancel·larà o no, sinó que resumeixen el comportament dominant de cada grup i permeten connectar el clustering amb la capa de decisió del sistema.

Perfil operatiu	Característica dominant	Interpretació dins del sistema
Planificador anticipat	Antelació elevada	Reserva feta amb molta antelació, amb risc de canvi de plans abans de l'arribada.
Reserva d'última hora	Antelació baixa	Reserva amb poc marge operatiu, on cal confirmar ràpidament la intenció d'arribada.
Viatger premium	Preu per hoste o despesa total elevada	Reserva amb alt valor econòmic, rellevant per protegir ingressos.
Turista familiar	Reserva familiar i/o nombre d'hostes elevat	Reserva amb major complexitat logística i necessitat de reduir incertesa.
Viatger estàndard	Valors propers al comportament mitjà	Reserva sense trets extrems, adequada per a gestió automatitzada.
Corporatiu fidel	Component corporatiu o recurrència positiva	Reserva on cal protegir la relació comercial i revisar el cas abans d'aplicar mesures restrictives.

Taula 6. Perfils operatius obtinguts a partir del clustering i interpretació dins del sistema IDSS.

Per donar suport visual a aquesta interpretació, s'han utilitzat diverses representacions complementàries. En primer lloc, s'ha construït un gràfic radar normalitzat per clúster. Aquest gràfic resumeix els trets principals de cada perfil a partir de variables quantitatives com l'antelació, les nits totals, el preu per hoste, les peticions especials, la despesa total i el nombre d'hostes. Aquesta visualització permet identificar ràpidament quines dimensions destaquen en cada grup i funciona com una primera aproximació a la lectura dels perfils.



Figura 23: Radar de perfils normalitzats per clúster

De manera complementària, s'ha construït una matriu aTLP (Annotated Traffic Light Panel) dels perfils de clúster. Aquesta visualització amplia la matriu TLP inicial, ja que no només incorpora variables numèriques, sinó també variables binàries i categòriques rellevants per a la interpretació del perfil. En concret, s'hi inclouen dimensions com l'antelació, les nits totals, el nombre d'hostes, la presència de reserva familiar, el preu per hoste, la despesa total, les peticions especials, les cancel·lacions prèvies, la recurrència del client, el segment de mercat, el canal de distribució i el risc associat al país d'origen.

Els colors de la matriu segueixen una lògica tipus semàfor. El verd indica un valor favorable o molt representatiu dins la lògica del perfil; el groc indica una situació intermèdia; el taronja representa un valor poc favorable o que requereix certa atenció; i el vermell indica un valor desfavorable, una absència d'aquell tret o una possible font de risc operatiu. Cal tenir en compte que aquests colors no s'han d'interpretar únicament com a valors alts o baixos en sentit estadístic, sinó com una lectura de negoci. Per exemple, un valor pot ser favorable perquè ajuda a definir clarament el perfil, mentre que un altre pot ser desfavorable perquè implica poca rendibilitat, poca informació útil o més risc d'actuació.




Figura 24: Matriu aTLP de perfils normalitzats per clúster.

Aquesta matriu ha estat especialment útil per passar d'una lectura purament numèrica dels clústers a una interpretació més propera al domini hotel·ler. A continuació, es descriu com s'ha interpretat cada clúster a partir dels valors favorables, intermedis i desfavorables observats.

El **clúster 0** s'ha interpretat com el perfil de **Planificador anticipat**. El tret més clar d'aquest grup és l'antelació, marcada com a favorable, fet que indica que aquestes reserves es fan amb molt marge abans de la data d'arribada. En canvi, variables com les nits totals, el nombre d'hostes, la reserva familiar, el preu per hoste i la despesa total apareixen com a desfavorables o poc destacades. Això suggereix que no es tracta d'un perfil especialment llarg, familiar ni d'alt valor econòmic. Les peticions especials apareixen en un nivell intermedi, mentre que el segment Offline TA/TO, el canal TA/TO i el risc del país introdueixen elements de vigilància. Per tant, aquest perfil representa reserves fetes amb molta antelació que poden requerir seguiment escalonat per mantenir el compromís del client fins a la data d'arribada.

El **clúster 1** correspon al perfil de **Reserva d'última hora**. En aquest cas, l'antelació apareix com a desfavorable, cosa que indica que el marge temporal abans de l'arribada és molt reduït. També es mostren com a poc destacades les nits totals, els hostes, la reserva familiar, la despesa total i la recurrència del client, fet que apunta a reserves simples, curtes i amb poca informació relacional. No obstant això, el segment de mercat i el canal de distribució apareixen com a Direct, cosa que és positiva des del punt de vista operatiu, ja que facilita el contacte amb el client i redueix la dependència d'intermediaris. La interpretació final és la d'un perfil de reserva ràpida i directa, on la prioritat és confirmar la intenció d'arribada i protegir l'inventari davant possibles no-shows o cancel·lacions d'últim moment.

El **clúster 2** s'ha interpretat com el perfil de **Viatger premium**. Aquest grup presenta valors favorables en variables relacionades amb el valor econòmic, especialment les nits totals, el preu per hoste i la despesa total. També presenta un risc del país baix, fet que contribueix a una lectura més favorable del perfil. En canvi, el nombre d'hostes i la reserva familiar no destaquen, de manera que no es tracta principalment d'un perfil familiar o de grup nombrós, sinó més aviat d'una reserva individual o de pocs hostes amb alt valor econòmic. La presència del segment

Online TA i del canal TA/TO indica certa dependència d'intermediaris, però el valor econòmic del perfil justifica una atenció més personalitzada. Per aquest motiu, dins del sistema IDSS aquest perfil és rellevant per protegir revenue i prioritzar accions de valor afegit abans que mesures genèriques.

El **clúster 3** s'ha assignat al perfil de **Turista familiar**. Els trets més definitoris són el nombre d'hostes i la variable de reserva familiar, que apareixen com a favorables i representatius del grup. Això indica que aquest clúster concentra reserves amb més persones i amb característiques pròpies d'un viatge familiar. En canvi, el preu per hoste és baix i la despesa total queda en un nivell menys favorable, cosa que suggereix que no és un perfil premium, sinó un perfil marcat sobretot per la complexitat logística. El segment Online TA i el canal TA/TO indiquen que moltes d'aquestes reserves provenen d'intermediaris. Per tant, la recomanació associada a aquest perfil no ha de centrar-se tant en incentius econòmics, sinó en reduir incertesa: confirmar habitació, llits, serveis familiars, horaris o necessitats especials abans de l'arribada.

El **clúster 4** representa el perfil de **Viatger estàndard**. Aquest és el grup més majoritari i es caracteritza per no presentar valors extremadament dominants en cap dimensió principal. L'antelació apareix en un nivell intermedi, mentre que el preu per hoste i les peticions especials apareixen en una situació de certa atenció, però sense arribar a definir un perfil clarament premium o complex. Variables com les nits totals, els hostes, la reserva familiar, la despesa total i la recurrència no destaquen, fet que reforça la interpretació d'un perfil habitual i proper al comportament mitjà del dataset. A nivell comercial, predomina Online TA i canal TA/TO, cosa que encaixa amb un patró de reserva freqüent en el sector. Per aquest motiu, dins del sistema IDSS aquest perfil s'associa a una gestió més automatitzada, amb escalat manual només quan el risc o el valor econòmic ho justifiquen.

Finalment, el **clúster 5** s'ha interpretat com a **Corporatiu fidel**. Aquest perfil no es pot entendre només a partir de les variables quantitatives clàssiques, ja que presenta valors baixos o poc favorables en antelació, nits totals, hostes, reserva familiar, preu per hoste i despesa total. Tanmateix, la seva identitat queda clara quan s'observen les variables categòriques i relacionals: el client repetidor apareix com a favorable, i tant el segment de mercat com el canal de distribució apareixen com a Corporate. Aquests elements indiquen una relació comercial més estable amb l'hotel, encara que la reserva concreta no tingui un valor econòmic elevat. Alhora, el risc del país i les cancel·lacions prèvies introdueixen un element de cautela. Per això, aquest perfil s'ha definit com a corporatiu fidel: no és necessàriament el més rendible per reserva individual, però sí un perfil on pot existir una relació comercial que convé preservar. Dins del sistema, això justifica una actuació més prudent, prioritzant la revisió manual o comercial abans d'aplicar mesures restrictives.

Aquesta interpretació mostra que els perfils no s'han assignat únicament a partir d'una variable concreta, sinó combinant diversos senyals. En alguns casos, com el Planificador anticipat, el Viatger premium o el Turista familiar, la interpretació és força directa perquè hi ha una o diverses variables quantitatives clarament dominants. En altres casos, com el Corporatiu fidel, la interpretació depèn més de variables categòriques i relacionals, com el segment de mercat, el canal de distribució i la recurrència del client. Per aquest motiu, l'aTLP és més complet que la matriu TLP inicial, ja que permet justificar millor la denominació final dels perfils.

Finalment, s'ha representat l'assignació final dels clústers en el pla PCA 2D, amb els centroides anotats, i s'ha inclòs una visualització de la distribució de mides dels perfils. Aquesta representació permet comprovar que alguns perfils apareixen més separats en l'espai projectat, mentre que altres se solapen parcialment. Aquest solapament és esperable, ja que les dues primeres components principals només resumeixen una part de la variabilitat total de les dades i no poden representar tota la informació utilitzada pel clustering.




Figura 25: Clústers en el pla PCA 2D amb centroides anotats i distribució de perfils interpretatius

La distribució dels perfils mostra que el **Viatger estàndard** és clarament el grup majoritari, amb aproximadament un 69,3% de les reserves. Això és coherent amb el fet que la majoria de reserves no presenten trets extrems i poden ser gestionades de manera més automatitzada. La **Reserva d'última hora** representa al voltant del 10,6%, el **Turista familiar** un 8,1% i el **Planificador anticipat** un 6,9%. Els perfils **Corporatiu fidel** i **Viatger premium** són més minoritaris, amb aproximadament un 3,4% i un 1,6% respectivament. Tot i ser grups petits, són importants des del punt de vista del sistema, ja que poden requerir estratègies diferenciades: el perfil premium per l'impacte econòmic i el corporatiu per la relació comercial.

6.6. Estabilitat interna dels clústers

Per avaluar la cohesió interna de la solució final, s'ha representat el gràfic de valors silhouette per observació, agrupats per clúster. Aquesta visualització permet comprovar si les observacions d'un mateix grup estan realment més properes al seu clúster que als clústers veïns.

Un valor mitjà positiu de silhouette indica que, en general, la partició és coherent. A més, si la majoria d'observacions de cada clúster presenten valors positius, es pot considerar que els grups tenen una separació raonable. En canvi, un clúster amb molts valors negatius seria menys estable i podria requerir una reinterpretació o fusió amb un altre grup.

En aquest projecte, aquesta anàlisi s'ha utilitzat com a comprovació addicional de la qualitat interna dels clústers. Tanmateix, la decisió final no depèn únicament d'aquesta mètrica, sinó també de la coherència dels perfils i de la seva utilitat dins del sistema de decisió.




Figura 26: Valors silhouette per observació agrupats per clúster, amb la mitjana global marcada

6.7. Variables més discriminants entre clústers

Per identificar quines variables contribueixen més a diferenciar els clústers, s'ha entrenat un Random Forest auxiliar utilitzant l'assignació de clúster com a variable objectiu. Aquest model no forma part del sistema predictiu ni s'utilitza per assignar noves reserves. La seva funció és exclusivament interpretativa: permet estimar quines variables expliquen millor la separació entre perfils.

Les variables més discriminants acostumen a estar relacionades amb la planificació temporal i el valor econòmic de la reserva, especialment `lead_time`, `adr_per_guest`, `spend_total` i `total_nights`. Aquest resultat és coherent amb l'objectiu del clustering, ja que aquests factors permeten distingir entre reserves anticipades, reserves d'alt valor, estades llargues i reserves més estàndard.

També apareixen variables vinculades al canal i al context, com `segment_enc`, `customer_type_enc` i `is_resort`, que ajuden a diferenciar comportaments comercials. Altres variables, com `booking_complexity`, `is_family_booking` o `previous_cancellations`, tenen un paper més específic, però són útils per identificar perfils com el turista familiar o el client recurrent amb risc històric.

Aquesta anàlisi confirma que els clústers no estan definits per variables arbitràries, sinó per dimensions operatives rellevants per al negoci hotelier. Per tant, la segmentació obtinguda pot utilitzar-se com a base contextual per al model de coneixement del sistema IDSS.




Figura 27: Variables més discriminants entre clústers segons el Random Forest auxiliar.

6.8. Exportació del resultat i ús dins del sistema IDSS

El resultat final del clustering s'ha exportat al fitxer `hotel_clustering_output.csv`. Aquest fitxer conserva les columnes del dataset original i afegeix únicament una nova columna: `cluster`. Aquesta decisió de disseny manté la sortida neta i desacoblada, ja que les etiquetes interpretatives, les regles d'actuació i les recomanacions es gestionen en mòduls separats del sistema.

Dins del sistema IDSS, el clustering s'utilitza com a mecanisme de perfilat. Quan arriba una nova reserva, el sistema genera les variables necessàries per al clustering, aplica el mateix escalat utilitzat durant l'entrenament i calcula la distància de la nova observació als centroides dels clústers. La reserva s'assigna al clúster més proper i, posteriorment, aquest clúster es tradueix en un perfil operatiu.

Aquest perfil s'envia a la capa de decisió juntament amb la probabilitat de cancel·lació generada pel model XGBoost. A partir d'aquests dos elements, la capa de regles pot adaptar la recomanació. Així, el clustering no genera una decisió per si mateix, sinó que aporta context per personalitzar les accions recomanades.

Aquest enfocament reforça el caràcter híbrid del sistema. El model supervisat aporta una estimació quantitativa del risc, el clustering aporta una lectura descriptiva del tipus de reserva i el model de coneixement transforma tota aquesta informació en una recomanació operativa.

La versió final del clustering corregeix les limitacions de la primera aproximació. En lloc d'aplicar els algorismes sobre una matriu d'alta dimensionalitat pensada per al model predictiu, s'ha construït una representació específica per al perfilat. Aquesta nova representació evita l'ús de one-hot encoding, redueix soroll i prioritza variables interpretables des del punt de vista hotelier.

El resultat és una segmentació més útil per al sistema IDSS. Els clústers no s'interpreten com a classes de cancel·lació, sinó com a perfils operatius que permeten contextualitzar el risc i modular les decisions. Això evita que el sistema tracti totes les reserves d'alt risc de la mateixa manera i permet adaptar les accions segons el tipus de reserva.

En conjunt, el clustering aporta una capa de coneixement descriptiu que complementa el model predictiu. La seva contribució principal és fer que la recomanació final no depengui només d'una probabilitat, sinó també del perfil de la reserva, del seu valor i de la manera més adequada d'intervenir.

7. Model de coneixement

El sistema proposat no es basa únicament en la probabilitat generada pel model predictiu, sinó que incorpora una capa de coneixement expert encarregada de transformar aquesta estimació en una recomanació operativa concreta. Aquesta capa constitueix el model de coneixement del sistema IDSS i actua com a element d'unió entre el model de Machine Learning, el perfil operatiu de la reserva i la presa de decisions dins del context hotel·ler.

L'objectiu principal del model de coneixement és evitar que la decisió es prengui només a partir d'un valor numèric de risc. En un entorn real de gestió hotelera, dues reserves amb una probabilitat de cancel·lació semblant poden requerir actuacions diferents segons el seu perfil, el seu valor econòmic, l'antelació de la reserva, el tipus de client o la relació comercial amb l'hotel. Per aquest motiu, el sistema combina tres elements: la probabilitat de cancel·lació estimada pel model XGBoost, el perfil operatiu assignat a partir del clustering i un conjunt de regles de negoci definides en un fitxer extern.

Aquest coneixement expert s'ha formalitzat en un fitxer de regles en format YAML. Aquesta decisió permet separar la lògica de decisió del codi del dashboard, fent que les accions recomanades siguin més fàcils de revisar, modificar o ampliar sense haver de reentrenar el model predictiu. Això és especialment rellevant en un context hotel·ler, on les polítiques comercials, la tolerància al risc i les prioritats operatives poden canviar segons la temporada, l'ocupació prevista o l'estratègia de revenue management.

En la versió actual del sistema, el model de coneixement segueix una estructura controlada i fàcilment interpretable: per a cada reserva es determina primer el nivell de risc i el perfil operatiu, i a partir d'aquesta combinació es recuperen les accions recomanades. D'aquesta manera, el sistema evita generar recomanacions contradictòries o massa disperses i ofereix al dashboard una sortida clara, accionable i orientada a la presa de decisions.

7.1. Estructura general del model de coneixement

El model de coneixement s'organitza al voltant de quatre elements principals: els llistats de risc, els criteris generals de negoci, els perfils operatius i les accions associades a cada combinació de perfil i nivell de risc.

En primer lloc, es defineixen els llistats de risc utilitzats per transformar la probabilitat de cancel·lació en una categoria interpretable pel dashboard. En lloc de mostrar únicament un valor numèric, el sistema classifica cada reserva en un nivell de risc, cosa que facilita la prioritització per part de l'usuari.

Aquesta discretització permet adaptar la intensitat de la resposta a la gravetat del cas. Les reserves de risc baix o mitjà poden gestionar-se habitualment amb comunicacions automàtiques o accions de seguiment lleugeres. En canvi, les reserves de risc alt o crític poden requerir una intervenció més directa, com una trucada, una revisió manual, una validació de dades o una actuació per part de revenue management.

Nivell de risc	Criteri
Baix	probabilitat inferior a 0,30
Mitjà	Probabilitat entre 0,30 i 0,55
Alt	Probabilitat entre 0,55 i 0,85
Crític	Probabilitat igual o superior a 0,85

Taula 7. Llindars de risc utilitzats pel model de coneixement.

En segon lloc, el fitxer de regles incorpora criteris generals de negoci que ajuden a contextualitzar les recomanacions. Entre aquests criteris hi ha valors de referència com el revenue mitjà i alt, l'ADR elevat, el lead time alt o extrem i la consideració de reserva urgent. Aquests criteris no funcionen com a regles independents que generin accions separades, sinó com a paràmetres que ajuden a construir una lògica de decisió coherent amb el domini hotelier.

En tercer lloc, el sistema utilitza els perfils operatius derivats del clustering. Cada perfil representa un tipus de reserva amb una lògica pròpia: reserves anticipades, d'última hora, premium, familiars, estàndard o corporatives. Aquesta informació permet adaptar el tipus d'acció recomanada al context de la reserva.

Finalment, el model de coneixement defineix accions específiques per a cada perfil i nivell de risc. Aquesta és la part central del sistema expert actual. En lloc d'aplicar un conjunt ampli de regles globals que es puguin solapar, el dashboard recupera les accions corresponents a la combinació perfil-risc i les mostra de manera estructurada a la fitxa d'intervenció.

7.2. Principis experts de decisió

Les regles del sistema no s'han definit com una simple correspondència entre probabilitat alta i acció intensa. Al contrari, segueixen una sèrie de principis experts propis del domini hotelier.

El primer principi és que **no totes les reserves amb risc alt mereixen el mateix esforç operatiu**. Una reserva d'alt valor econòmic o vinculada a un client important pot justificar una actuació personalitzada, mentre que una reserva estàndard de menor impacte pot gestionar-se de manera més eficient mitjançant canals automàtics. Aquesta idea és essencial des del punt de vista de negoci, perquè el sistema no només ha d'identificar risc, sinó també ajudar a decidir on val la pena invertir temps i recursos.

El segon principi és que les recomanacions han de ser **executables per equips reals**. Per això, les accions proposades es concreten en canals i tasques que poden ser assumides per recepció, reserves, revenue management o direcció. El sistema no genera recomanacions abstractes, sinó accions com enviar un email, contactar per SMS, fer una trucada, revisar les dades de contacte, validar una garantia o escalar el cas a un responsable.

El tercer principi és que el sistema prioritza **reduir la incertesa abans d'aplicar mesures restrictives**. En molts casos, una cancel·lació potencial pot anticipar-se mitjançant una comunicació clara, una reconfirmació, un recordatori o una alternativa de canvi de dates. Per això, les accions inicials se centren sovint en confirmar la intenció d'arribada, reforçar la confiança del client i facilitar la modificació de la reserva abans que la cancel·lació.

El quart principi és que s'ha de protegir la **relació comercial amb clients de valor**, especialment en perfils corporatius o recurrents. En aquests casos, el sistema evita recomanar mesures agressives de manera automàtica i prioritza la revisió manual, el contacte comercial o la coordinació amb l'equip responsable del compte.

Finalment, el sistema diferencia entre accions de **baix cost operatiu** i accions que requereixen intervenció humana. L'email o l'SMS poden aplicar-se de manera escalable a molts casos, mentre que una trucada, una revisió per direcció o una intervenció de revenue management s'han de reservar per situacions on el risc i l'impacte econòmic ho justifiquin.

7.3. Tractament de `deposit_type` dins del sistema

Una decisió important de la versió final és el tractament de la variable `deposit_type`. Aquesta variable no s'utilitza com a entrada del model predictiu, ja que durant l'anàlisi exploratòria s'ha observat que podia introduir una dependència excessiva respecte al resultat final de la reserva o a convencions internes de registre.

No obstant això, `deposit_type` es conserva com a informació contextual visible dins del dashboard. Aquesta separació és important: la variable no intervé en el càlcul de la probabilitat de cancel·lació ni modifica automàticament les accions recomanades, però pot ajudar l'usuari a interpretar millor les condicions comercials de la reserva.

Per exemple, una reserva sense dipòsit pot ser percebuda per l'equip de reserves com menys compromesa que una reserva amb algun tipus de garantia. En canvi, una reserva no reemborsable pot requerir una lectura diferent, ja que afegir més fricció econòmica podria no ser adequat. Tot i això, en la versió actual del sistema, aquesta interpretació queda en mans de l'usuari i no s'aplica com una regla automàtica independent.

Aquesta decisió reforça la separació entre predicció i decisió. El model predictiu es manté metodològicament més net, mentre que el dashboard conserva informació contractual útil per al personal de l'hotel.

7.4. Perfils operatius utilitzats

El model de coneixement treballa amb sis perfils operatius principals derivats del clustering. Aquests perfils no representen classes supervisades ni etiquetes de cancel·lació, sinó agrupacions interpretatives que permeten contextualitzar la reserva i adaptar millor la recomanació.

Perfil operatiu	Lògica principal	Estratègia de decisió
Planificador anticipat	Reserva feta amb molta antelació	Seguiment escalonat, reconfirmació i facilitació de canvis
Reserva d'última hora	Poc marge abans de l'arribada	Confirmació immediata, validació de dades i protecció d'inventari
Viatger premium	Alt valor econòmic o ADR elevat	Atenció personalitzada i protecció del revenue
Turista familiar	Reserva familiar o de major complexitat logística	Reducció d'incertesa sobre serveis, habitació i necessitats familiars
Viatger estàndard	Segment majoritari sense trets extrems	Automatització i escalat només si el risc o el revenue ho justifiquen
Corporatiu fidel	Reserva vinculada a empresa, acord comercial o client corporatiu	Protecció de la relació comercial i revisió manual abans d'aplicar restriccions

Taula 8. Perfils operatius utilitzats pel model de coneixement.

El perfil **Planificador anticipat** agrupa reserves fetes amb molta antelació. El risc principal en aquest cas és que el client canviï de plans abans de la data d'arribada. Per això, les accions associades a aquest perfil se centren en mantenir la reserva activa, reforçar el vincle amb el viatge i facilitar canvis de dates abans que cancel·lacions.

El perfil **Reserva d'última hora** representa reserves amb poc marge abans de l'arribada. En aquest cas, la prioritat és confirmar ràpidament la intenció d'arribada i evitar que una habitació quedi bloquejada sense una garantia clara. Les accions recomanades tendeixen a ser immediates, com confirmacions ràpides, SMS, trucades o revisió de dades.

El perfil **Viatger premium** correspon a reserves d'alt valor econòmic, ja sigui per un ADR elevat, una estada llarga o una despesa total important. En aquest cas, la lògica de negoci és protegir el revenue sense deteriorar l'experiència del client. Per això, les accions recomanades prioritzen la personalització, el contacte directe i els serveis de valor afegit abans que els descomptes directes.

El perfil **Turista familiar** identifica reserves amb infants, diversos hostes o una major complexitat logística. En aquests casos, el risc pot estar relacionat amb dubtes sobre llits, habitacions, serveis per a nens, horaris o necessitats específiques. Les accions se centren a reduir incertesa abans de l'arribada i confirmar que les condicions de l'estada responen a les expectatives del client.

El perfil Viatger estàndard representa el segment majoritari o sense trets extrems. La seva gestió ha de ser eficient i escalable. Per això, el sistema recomana principalment accions automàtiques, com emails, SMS o pre-check-in, i reserva l'escalat manual per als casos en què el risc o el valor econòmic ho justifiquin.

Finalment, el perfil **Corporatiu fidel** representa reserves vinculades a empreses, acords comercials o clients corporatius. La prioritat és protegir la relació comercial i evitar actuacions automàtiques que puguin perjudicar un acord vigent. En aquests casos, el sistema recomana una revisió més prudent i, si cal, la intervenció de responsables comercials o revenue management.

7.5. Funcionament de les regles per nivell de risc

Per a cada perfil, el model de coneixement defineix accions diferenciades segons el nivell de risc: baix, mitjà, alt o crític. Aquesta estructura permet adaptar la intensitat de la intervenció a la probabilitat estimada pel model.

En el nivell **baix**, les accions solen ser automàtiques i de baix cost operatiu. L'objectiu és mantenir la comunicació amb el client i reforçar la reserva sense generar una càrrega innecessària per al personal de l'hotel. En aquest nivell, el sistema acostuma a recomanar emails de confirmació, informació útil sobre l'estada, pre-check-in digital o petits serveis opcionals.

En el nivell **mitjà**, les accions busquen reduir incertesa i augmentar el compromís del client amb la reserva. Aquí apareixen comunicacions més específiques, com recordatoris, SMS de confirmació, emails preventius o alternatives de canvi de dates abans que cancel·lació. En alguns perfils, també es pot proposar una revisió manual si la reserva presenta valor econòmic rellevant o si el marge operatiu és reduït.

En el nivell **alt**, el sistema recomana actuacions més directes. Aquestes poden incloure trucades, revisió manual, validació de dades, consulta amb revenue management o preparació d'una acció preventiva personalitzada. La idea no és aplicar mesures restrictives de manera automàtica, sinó incrementar el nivell d'atenció quan el risc i el context de la reserva ho justifiquen.

En el nivell **crític**, el sistema activa accions de màxima prioritat. Aquest nivell s'utilitza quan la probabilitat de cancel·lació és molt elevada i la reserva pot tenir un impacte important sobre l'ocupació o els ingressos. Les accions poden incloure escalat a supervisió, revisió d'inventari, intervenció de revenue management, contacte directe amb el client o preparació d'escenaris de revenda si la reserva no es confirma.

En la versió actual del sistema, no es recomana overbooking automàtic. Quan el risc és crític, el sistema pot suggerir revisar l'inventari o analitzar escenaris de revenda, però la decisió final queda en mans de l'equip responsable. Aquesta decisió és coherent amb la naturalesa d'un IDSS: el sistema dona suport a la decisió, però no substitueix el criteri professional.

7.6. Integració de les regles dins del dashboard

El model de coneixement està integrat dins del motor IDSS que alimenta el dashboard. Per a cada reserva, el sistema segueix un flux estructurat: primer calcula la probabilitat de cancel·lació amb el model XGBoost; després assigna el perfil operatiu a partir del clustering; a continuació determina el nivell de risc segons els llindars definits; finalment recupera les accions del YAML associades a la combinació de perfil i nivell de risc.

La sortida d'aquest procés inclou el nivell de risc, el perfil, la prioritat de la reserva, els canals recomanats, el moment d'actuació i les accions concretes que s'han de proposar a l'usuari. Aquesta informació es mostra al dashboard en forma de fitxes d'intervenció, alertes i accions programades.

Un aspecte important és que el dashboard no mostra només la probabilitat de cancel·lació. També presenta la informació de manera orientada a la decisió: quin perfil té la reserva, quin nivell de risc presenta, quins canals són més adequats i quina actuació es recomana. Això permet que el personal de l'hotel no hagi d'interpretar manualment cada predicció, sinó que rebi una proposta operativa ja estructurada.

A més, les accions del YAML estan redactades de manera que el dashboard pugui identificar canals i tipus d'intervenció. Per exemple, si una acció menciona email, SMS, trucada, revisió manual, revenue management o direcció, el sistema pot classificar-la visualment i mostrar-la amb una categoria operativa clara. Aquesta classificació ajuda a convertir el resultat del sistema en una llista d'actuacions comprensible per a l'usuari.

Aquesta integració converteix el dashboard en una eina de treball i no només en una visualització analítica. L'usuari pot consultar les reserves prioritzades, obrir la fitxa d'un cas concret, veure les accions recomanades i preparar la intervenció corresponent.

8. Interfície i dashboard operatiu

La interfície desenvolupada té com a objectiu convertir el sistema IDSS en una eina funcional i comprensible per a un entorn hotel·ler. No s'ha plantejat només com una visualització de resultats del model, sinó com un entorn operatiu capaç de connectar les diferents parts del projecte: la predicció de cancel·lació, el perfilat de reserves mitjançant clustering, el model de coneixement basat en regles i l'activació d'accions preventives.

El sistema s'ha implementat sota la identitat de **Grand Meridian Hotel**, amb dues interfícies diferenciades. D'una banda, hi ha una **web pública de reserva**, orientada al client, des d'on es pot crear una nova reserva. D'altra banda, hi ha un **dashboard intern**, orientat al personal de l'hotel, on es visualitzen les reserves a tractar, el risc de cancel·lació, el perfil operatiu assignat i les accions recomanades.

Aquesta separació és important perquè reproduceix millor un escenari real. En un hotel, la reserva pot originar-se en una pàgina pública, un motor de reserves o un canal comercial extern, mentre que l'anàlisi de risc i la presa de decisions es duen a terme posteriorment en una eina interna utilitzada per recepció, reserves, revenue management o direcció. D'aquesta manera, la interfície diferencia clarament entre el flux visible per al client i el flux intern de suport a la decisió.

Des d'una perspectiva de negoci, el valor principal de la interfície és que transforma una predicció tècnica (la probabilitat de cancel·lació) en una recomanació operativa. El personal de l'hotel no ha d'interpretar manualment cada score, sinó que rep una lectura estructurada del cas: quin risc presenta la reserva, quin perfil té, quin impacte econòmic pot tenir i quina acció es recomana aplicar.

8.1. Arquitectura funcional de la interfície

La interfície es basa en una arquitectura modular formada per quatre blocs principals: la web pública de reserva, el motor IDSS, el dashboard intern i l'agent d'email.

El primer bloc és la **web pública de reserva** (`reserva_web.html`). Aquesta pàgina representa el punt d'entrada del client. Permet crear una nova reserva introduint informació sobre l'hotel, la data d'arribada, el nombre de nits, el nombre d'hostes, el tipus d'habitació, el règim d'àpats, el país de residència, el tipus de dipòsit, les peticions especials i les dades de contacte. Un cop confirmada, la reserva queda registrada localment i pot ser incorporada al dashboard intern.

El segon bloc és el **motor IDSS**, implementat principalment en Python (`idss_engine.py`). Aquest motor és l'encarregat de carregar el model predictiu entrenat, recuperar les dades de clustering, llegir les regles de negoci i generar la informació que alimentarà el dashboard. Per a cada reserva, calcula la probabilitat de cancel·lació amb XGBoost, assigna un clúster i un perfil, determina el nivell de risc i recupera les accions recomanades segons el fitxer de regles.

El tercer bloc és el **dashboard intern** (`index.html`, `styles.css`, `app.js` i `dashboard_data.js`). Aquest dashboard mostra una cartera de reserves prioritzada i permet

analitzar cada cas des d'una perspectiva operativa. El fitxer `dashboard_data.js` conté els resultats ja materialitzats pel motor: reserves visibles, probabilitat de cancel·lació, nivell de risc, perfil, canals recomanats, accions del YAML i dades necessàries per al funcionament del dashboard. Això permet obrir la interfície de manera local sense haver de recalculat contínuament totes les prediccions.

El quart bloc és l'**agent d'email**, implementat amb FastAPI. Aquest component permet enviar correus de confirmació de reserva i, en casos d'alt risc, correus preventius personalitzats. Així, la interfície no només recomana accions, sinó que pot iniciar una actuació concreta quan es disposa de les credencials SMTP corresponents.

En conjunt, el flux funcional és el següent: una reserva es crea o s'importa, el sistema calcula el risc amb el model predictiu, assigna un perfil operatiu amb clustering, aplica les regles de negoci i mostra una recomanació al dashboard. Aquest flux reflecteix la naturalesa híbrida de l'IDSS: combina dades, models, coneixement expert i acció operativa.

8.2. Web pública de reserva

La web pública de reserva és la interfície orientada al client. La seva funció és simular el procés de creació d'una reserva en un entorn hotel·ler. A diferència del dashboard intern, aquesta pàgina no mostra informació analítica, nivells de risc ni recomanacions de negoci. El client només veu un formulari de reserva i, un cop finalitzat el procés, una pantalla de confirmació.

La pàgina està organitzada en un flux de dos passos. El primer pas se centra en la **selecció de l'estada i de l'habitació**. El client pot escollir entre City Hotel i Resort Hotel, seleccionar el tipus d'habitació, indicar la data d'arribada, el nombre de nits i el nombre d'hostes. El sistema calcula automàticament el preu per nit segons l'habitació seleccionada i mostra un resum econòmic de la reserva.

PASO 1

Elige estancia y habitación

La habitación marca el precio por noche y la capacidad máxima de la reserva.

Hotel



City Hotel
En el corazón de la ciudad, a 5 min de todo



Resort Hotel
Relax total frente al mar, spa y piscina

Tipo de habitación



Estándar
desde 92€/noche
max 2 personas



Estándar Superior
desde 94€/noche
max 2 personas



Superior
desde 166€/noche
max 3 personas



Superior Amplia
desde 118€/noche
max 4 personas



Familiar
desde 130€/noche
max 4 personas



Deluxe
desde 161€/noche
max 3 personas



Suite
desde 179€/noche
max 2 personas



Suite Presidencial
desde 204€/noche
max 2 personas

Precio por noche

Precio fijado por la habitación seleccionada.

92 €/noche

Régimen de comida

Solo alojamiento +0 €

Con desayuno +15 €/noche

Media pensión +35 €/noche

Pensión completa +55 €/noche

Fecha de llegada

23/06/2026

Número de noches

1

Adultos

2

Niños

0

Capacidad máxima: 2 huéspedes. Los niños menores de 2 años no cuentan como huéspedes. **Capacidad completa.**

Anterior **Siguiente**


TOTAL ESTIMADO

92 €

Hotel	City Hotel
Llegada	23 de junio de 2026
Noches	1
Huéspedes	2
Habitación	Estándar
Régimen	Solo alojamiento
Precio total	92 €

Figura 28: Formulari d'estada i habitació de la web pública de reserva

El segon pas recull les **preferències i dades del client**. En aquesta part s'introdueixen el nom, el correu electrònic, el país de residència, el tipus de dipòsit i les peticions especials. També es mostra el risc del país de forma simplificada dins del formulari, però sense exposar cap predicció de cancel·lació ni cap classificació interna del client.



PASO 2

Preferencias del huésped

Indica residencia y selecciona las peticiones disponibles para tu habitación.

Nombre y apellidos

Email del huésped

Tipo de depósito

No Deposit

País de residencia

Portugal

Peticiones especiales

Básicas

☐ Cuna ☐ Habitación tranquila ☐ Sin gluten ☐ Alergia alimentaria

0 de 3 peticiones seleccionadas para esta habitación.

TOTAL ESTIMADO

92 €

Hotel	City Hotel
Llegada	23 de junio de 2026
Noches	1
Huéspedes	2
Habitación	Estándar
Régimen	Solo alojamiento
Precio total	92 €

[Anterior](#) [Confirmar reserva](#)

Figura 29: Formulari de preferències de la web pública de reserva

Aquesta web incorpora algunes restriccions realistes. Per exemple, la capacitat de l'habitació limita el nombre d'hostes, i les peticions especials disponibles depenen del tipus d'habitació seleccionada. Això reforça la idea que la interfície no és un formulari genèric, sinó una simulació més propera a un motor de reserva hotelera.

Quan el client confirma la reserva, la web genera un objecte de reserva amb les variables necessàries perquè el sistema IDSS pugui processar-la. Aquest objecte inclou tant les dades introduïdes pel client com variables derivades necessàries per al model i el clustering, com `lead_time`, `arrival_date_month`, `arrival_date_week_number`, `total_nights`, `total_guests`, `adr`, `adr_per_guest`, `meal`, `market_segment`, `distribution_channel`, `customer_type`, `country_risk`, `previous_cancellations`, `has_agent`, `has_company`, `is_family_booking` i altres variables necessàries per mantenir la coherència amb l'entrenament.

La reserva es desa localment mitjançant `localStorage` sota la clau utilitzada pel sistema per compartir reserves web amb el dashboard. També es fa servir `window.name` com a mecanisme de transferència temporal entre pàgines. Aquesta solució permet simular el flux complet sense

necessitat d'una base de dades persistent. En un desplegament real, aquest mecanisme seria substituït per una API connectada al PMS o al motor de reserves de l'hotel.

Un aspecte important és que la web pública **no dona accés al dashboard intern** un cop finalitzada la reserva. Això manté la separació entre el client i l'eina interna de gestió. El client només rep la confirmació de la reserva, mentre que l'anàlisi de risc queda reservada al personal de l'hotel.

La reserva creada des de la web pública queda preparada per ser avaluada pel sistema IDSS. El sistema calcula la probabilitat de cancel·lació amb el model XGBoost exportat al navegador. Aquesta probabilitat es transforma en un nivell de risc segons els llindars definits al model de coneixement: baix, mitjà, alt o crític. Paral·lelament, la reserva s'assigna al clúster més proper utilitzant les variables compactes del clustering i la distància als centroides. D'aquesta manera, s'obté també el perfil de la reserva.

Finalment, el sistema recupera les accions recomanades del YAML a partir de la combinació entre perfil i nivell de risc. Aquesta és la lògica central de decisió de la versió actual: el dashboard no es basa en regles globals independents, sinó en un pla d'actuació definit per perfil i nivell de risc. Això permet generar recomanacions més netes, menys contradictòries i més fàcils d'interpretar.

Tot i que el dashboard conserva un formulari intern de "nova reserva" útil per a proves locals, el flux principal de creació de reserves s'ha plantejat a través de la web pública independent. Aquesta decisió reforça la separació entre el procés de reserva del client i el procés intern de gestió del risc.

8.3. Dashboard intern del sistema

El dashboard intern és l'eina principal per al personal de l'hotel. El seu objectiu és presentar una cartera de reserves prioritzada i facilitar la presa de decisions sobre quines reserves requereixen actuació preventiva.

A diferència de la web pública, el dashboard sí que mostra informació interna del sistema: probabilitat de cancel·lació, nivell de risc, perfil, valor econòmic estimat, canals recomanats, causes detectades i accions proposades. Aquesta informació està pensada per a usuaris interns i no s'exposa al client.

La part superior del dashboard mostra una visió general de la situació operativa: nombre de reserves, casos que requereixen intervenció prioritària, probabilitat mitjana de cancel·lació, revenue en risc i accions pendents. Aquests indicadors permeten tenir una primera lectura de la pressió operativa del dia.

També s'inclou un calendari de risc per data d'arribada. Aquest calendari permet veure en quins dies es concentren reserves amb risc alt o crític, així com les accions programades. Aquesta funcionalitat és útil per a revenue management, perquè no totes les cancel·lacions tenen el mateix impacte segons la data. Una habitació bloquejada en temporada alta o en una data de molta demanda pot requerir una actuació més ràpida que una reserva equivalent en un període de baixa ocupació.



Figura 30: Inici del dashboard interactiu

També s'inclou un calendari de risc per data d'arribada. Aquest calendari permet veure en quins dies es concentren reserves amb risc alt o crític, així com les accions programades. Aquesta funcionalitat és útil per a revenue management, perquè no totes les cancel·lacions tenen el mateix impacte segons la data. Una habitació bloquejada en temporada alta o en una data de molta demanda pot requerir una actuació més ràpida que una reserva equivalent en un període de baixa ocupació.

A més, el dashboard incorpora gràfics agregats que mostren la distribució de reserves per nivell de risc i per perfil. Aquesta visió ajuda a entendre si el risc està concentrat en un segment concret, com reserves premium, reserves familiars, reserves d'última hora o corporatives, o si està repartit de manera més homogènia.

RESERVAS ACTIVAS						
Ordenadas por urgencia de tratamiento						
Buscar reserva, perfil o canal...						
Todas Critico Alto Medio Bajo						
RESERVA	PERFIL	LLEGADA	RIESGO	VALOR	DEPOSITO	ACCION
R BK-20260238 Resort Hotel - 2 huéspedes - 2 noches	Corporativo Fiel Offline TA/TO - TA/TO	4 October 2015 275 días de antelación	CRITICO - 98,8 %	100 € ADR 50 €	Non Refund	Pendiente
R BK-20263594 Resort Hotel - 2 huéspedes - 2 noches	Corporativo Fiel Groups - TA/TO	15 July 2015 166 días de antelación	CRITICO - 98,2 %	243 € ADR 122 €	Non Refund	Pendiente
R BK-20263863 Resort Hotel - 2 huéspedes - 7 noches	Corporativo Fiel Groups - TA/TO	2 September 2015 244 días de antelación	CRITICO - 94,1 %	56 € ADR 8 €	No Deposit	Pendiente
C BK-20263153 City Hotel - 2 huéspedes - 2 noches	Corporativo Fiel Groups - TA/TO	9 April 2016 190 días de antelación	CRITICO - 97 %	140 € ADR 70 €	No Deposit	Pendiente
C BK-20260927 City Hotel - 2 huéspedes - 2 noches	Corporativo Fiel Online TA - TA/TO	8 January 2016 1 días de antelación	CRITICO - 88,6 %	135 € ADR 68 €	No Deposit	Pendiente
R BK-20263614 Resort Hotel - 2 huéspedes - 8 noches	Planificador Anticipado Online TA - TA/TO	27 August 2015 237 días de antelación	CRITICO - 97,4 %	824 € ADR 103 €	No Deposit	Pendiente
C BK-20263105 City Hotel - 2 huéspedes - 2 noches	Viajero Estandar Groups - TA/TO	30 March 2017 629 días de antelación	CRITICO - 98,6 %	124 € ADR 62 €	Non Refund	Pendiente
R BK-20263434 Resort Hotel - 4 huéspedes - 10 noches	Turista Familiar Online TA - TA/TO	3 July 2017 347 días de antelación	CRITICO - 89,6 %	1840 € ADR 184 €	No Deposit	Pendiente
R BK-20262096 Resort Hotel - 2 huéspedes - 3 noches	Reserva de Ultima Hora Groups - TA/TO	25 May 2017 462 días de antelación	CRITICO - 97,3 %	234 € ADR 78 €	Non Refund	Pendiente
C BK-20260839 City Hotel - 2 huéspedes - 4 noches	Planificador Anticipado Groups - TA/TO	25 August 2015 312 días de antelación	ALTO - 84,9 %	248 € ADR 62 €	No Deposit	Pendiente
C BK-20261739 City Hotel - 2 huéspedes - 2 noches	Planificador Anticipado Groups - TA/TO	23 September 2015 341 días de antelación	ALTO - 84,3 %	124 € ADR 62 €	Non Refund	Pendiente
C BK-20262631 City Hotel - 2 huéspedes - 4 noches	Planificador Anticipado Groups - TA/TO	15 August 2015 302 días de antelación	ALTO - 84,7 %	248 € ADR 62 €	No Deposit	Pendiente

Figura 31: Llistat del dashboard que mostra les reserves ordenades per risc

La zona principal de treball és la taula de reserves. Per cada reserva es mostra l'identificador, el perfil assignat, la data d'arribada, el canal comercial, el lead time, el nivell de risc, la probabilitat de cancel·lació, l'ADR, el valor estimat i l'estat de la intervenció. Aquesta taula permet fer cerques i filtres, de manera que l'usuari pot centrar-se ràpidament en els casos més rellevants.

Les reserves es mostren ordenades per un score d'urgència. Aquest score combina el nivell de risc, la probabilitat de cancel·lació, el valor econòmic estimat, el lead time, l'historial de cancel·lacions i la prioritat definida per les regles. Això permet que les reserves més sensibles apareguin en primer lloc.

8.3.1. Fitxa d'intervenció per reserva

Un dels elements més importants del dashboard és la fitxa detallada d'intervenció. Quan l'usuari selecciona una reserva de la taula, s'obre un panell lateral amb la informació necessària per entendre el cas i decidir com actuar.

La fitxa està pensada per respondre tres preguntes operatives bàsiques: **què passa, què cal fer i per a què serveix**. Aquesta estructura és molt útil perquè evita que l'usuari hagi de llegir una gran quantitat de dades disperses. El sistema resumeix el cas en una lectura orientada a la decisió.

En primer lloc, la fitxa mostra el nivell de risc i la probabilitat de cancel·lació. També indica l'estat de la intervenció, que pot estar pendent o executada. Això permet distingir entre reserves encara no tractades i reserves sobre les quals ja s'ha aplicat alguna acció.



Figura 32: Capçalera de la fitxa d'intervenció d'una reserva concreta

En segon lloc, la fitxa mostra el perfil assignat per clustering. Els perfils utilitzats són: Planificador anticipat, Reserva d'última hora, Viatger premium, Turista familiar, Viatger estàndard i Corporatiu fidel. Aquesta informació contextualitza la reserva i permet adaptar la lectura del risc. Per exemple, un risc alt en una reserva premium pot justificar una actuació personalitzada, mentre que un risc semblant en una reserva estàndard pot gestionar-se amb canals més automatitzats.

La fitxa també mostra informació operativa de la reserva: hotel, data d'arribada, valor estimat, segment de mercat, canal de distribució, tipus de dipòsit, durada de l'estada, nombre d'hostes, habitació, règim d'àpats, historial de cancel·lacions, país i nivell de risc del país. En aquest punt, `deposit_type` apareix com a informació contextual visible, però no forma part del model predictiu ni activa regles independents.

Perfil TLP Corporativo Fiel	Llegada 4 October 2015
Valor estimado 100 €	Canal Offline TA/TO - TA/TO
Tipo deposito Non Refund	Estancia 2 noches - 2 huéspedes
Huesped No disponible	Email huesped No disponible
Habitacion y regimen Tipo A - HB Tipo A: habitacion estandar. HB: media pension.	Historial 26 cancelacion(es) previa(s). No tratar como cliente nuevo: ya existe historial de cancelacion.
Origen de la reserva Pais: Italia (ITA) - riesgo pais High - 0 peticion(es) especial(es) El pais procede de dataset_5000.csv; el nivel de riesgo pais procede de las variables preparadas para el IDSS.	

Figura 33: Informació operativa d'una reserva concreta

A continuació, la fitxa presenta els canals recomanats. Aquests canals provenen del YAML i poden incloure email, SMS, trucada, revisió manual, revenue management o direcció. El sistema identifica el tipus d'acció a partir del contingut de les recomanacions i el mostra de manera visual, facilitant que l'usuari entengui ràpidament com ha d'actuar.

Canales recomendados

llamada email manual

Lectura concreta del caso

Esta reserva tiene 98,8 % de probabilidad estimada de cancelacion. Llega el 4 October 2015 y se hizo con 275 dias de antelacion. Hay 26 cancelacion(es) previa(s) asociadas. El pais de origen (Italia (ITA)) esta marcado como riesgo alto en las reglas del IDSS.

Probabilidad de cancelacion critica calculada por XGBoost

Perfil TLP asignado desde el cluster 5: Corporativo Fiel

Variables distintivas del cluster: repeticion o relacion comercial; mayor importancia del CRM; confirmacion con contacto corporativo

La recomendacion sale del perfil Corporativo Fiel, asignado por cluster 5, y del nivel de riesgo calculado para la reserva.

Figura 34: Canals recomanats i lectura operativa d'una reserva concreta

També s'inclou una secció de lectura concreta del cas, amb les causes detectades pel motor. Aquestes causes poden indicar, per exemple, que la probabilitat de cancel·lació és alta, que el perfil prové d'un clúster concret o que determinades variables del clúster són distintives. Aquesta explicació no s'ha d'interpretar com una causalitat estricta, sinó com una ajuda per entendre per què el sistema ha prioritzat aquella reserva.

Opciones de actuacion

1

Activar revisión conjunta entre reservas y account manager antes de modificar condiciones comerciales.

LLAMADA

Recomendado para una reserva critico: permite confirmar intencion, resolver dudas y registrar la respuesta.
Programar 10 o 5 o 2 dias antes de la llegada. Se puede aplicar sola o combinada con otras opciones del plan.

Preparar llamada

Marcar realizada

2

Llamada prioritaria al responsable corporativo para confirmar si existe cambio estructural en viajes de empresa.

LLAMADA

Recomendado para una reserva critico: permite confirmar intencion, resolver dudas y registrar la respuesta.
Programar 10 o 5 o 2 dias antes de la llegada. Se puede aplicar sola o combinada con otras opciones del plan.

Preparar llamada

Marcar realizada

3

Si se detecta riesgo repetido, abrir revisión del acuerdo corporativo y condiciones de cancelación futuras.

REVISION

Sirve para que el equipo revise el caso antes de aplicar una medida mas fuerte.
Programar 10 o 5 o 2 dias antes de la llegada. Se puede aplicar sola o combinada con otras opciones del plan.

Marcar para revisar

Marcar realizada

Figura 35: Exemples d'accions proposades pel sistema donada una reserva

Finalment, la fitxa mostra les opcions d'actuació. Cada acció es presenta com una targeta amb una explicació breu, el canal associat i botons per preparar l'acció o marcar-la com a realitzada. Si es prepara una trucada, SMS, revisió o garantia, el sistema pot afegir la tasca al calendari operatiu. Si l'acció és un email i la reserva compleix les condicions necessàries, el dashboard pot intentar enviar-lo mitjançant l'agent d'email.

8.3.2. Agent d'email i comunicació amb el client

El sistema incorpora un agent d'email local que permet convertir determinades recomanacions en una comunicació real dirigida al client. Aquest agent està implementat amb FastAPI i utilitza SMTP per enviar els missatges. Hi ha dos fluxos d'email diferenciats.

El primer és l'**email automàtic de confirmació de reserva**. Aquest correu s'envia quan un client completa una reserva des de la web pública. El missatge es genera amb una plantilla fixa i inclou les dades principals de la reserva: localitzador, hotel, data d'arribada, durada de l'estada, nombre d'hostes, tipus d'habitació, règim d'àpats, tipus de dipòsit i import estimat. Aquest email no utilitza cap model generatiu ni exposa informació interna del sistema. La seva funció és confirmar al client que la reserva ha estat registrada correctament.

danipastormiguel@gmail.com
5:38 PM (3 minutes ago)
to me

Hola paquito chocolatero,

Su reserva ha sido registrada correctamente. Estos son los datos principales:

- Localizador: WEB-0703133
- Hotel: City Hotel
- Llegada: 22 June 2026
- Estancia: 1 noche(s), 2 huesped(es)
- Habitación: tipo A
- Regimen: SC
- Tipo de deposito: No Deposit
- Importe estimado: 92.00 EUR

El equipo del hotel revisara la reserva y se pondra en contacto con usted si necesita algun dato adicional.

Atentamente,
Equipo de Reservas
Grand Meridian Hotel
reservas@grandmeridian.example
+34 900 000 000

El segon flux és l'**email preventiu per a reserves d'alt risc o risc crític**. Aquest email es pot enviar des del dashboard intern quan la reserva té risc ALTO o CRITICO i disposa d'un correu electrònic vàlid mitjançant . En aquest cas, el dashboard envia al backend informació com l'identificador de la reserva, el nom del client, l'hotel, la data d'arribada, el perfil operatiu, el nivell intern de risc, les causes detectades i les accions recomanades.

A diferència del correu de confirmació, aquest segon tipus de missatge es genera de manera personalitzada mitjançant una **API de ChatGPT**. El backend utilitza la informació de la reserva i l'acció recomanada pel sistema per construir un prompt específic, a partir del qual es **redacta un email adaptat al cas concret**. Això permet que la comunicació no sigui genèrica, sinó coherent amb el context de la reserva: per exemple, pot orientar-se a confirmar la intenció d'arribada, recordar informació important de l'estada, resoldre possibles dubtes o

reforçar el compromís del client amb la reserva. D'aquesta manera, la recomanació generada pel sistema IDSS es transforma en una comunicació real i personalitzada, mantenint un to professional i adequat per al client.

Tot i això, el missatge enviat al client no menciona mai la probabilitat de cancel·lació, el model XGBoost, el nivell de risc ni cap etiqueta interna del sistema. Aquesta decisió és molt important des del punt de vista de l'experiència de client: el client rep una comunicació útil i natural, sense percebre que està sent classificat per un sistema predictiu.

Estimado Pau Escobar,

Le confirmamos su reserva en el City Hotel para el 15 de julio de 2026. Entendemos que organizar unas vacaciones familiares puede generar algunas dudas y queremos asegurarnos de que su experiencia sea lo más cómoda posible.

Si necesita realizar cambios en sus fechas o tiene requerimientos específicos para su estancia, no dude en contactarnos. Estamos aquí para ayudarle a encontrar la mejor solución.

Agradecemos su confianza y esperamos darle la bienvenida pronto.

Atentamente,
Equipo de Reservas
Grand Meridian Hotel
reservas@grandmeridian.example
+34 900 000 000

Des del punt de vista de negoci, l'agent d'email aporta valor perquè permet actuar ràpidament sobre reserves sensibles. En lloc de limitar-se a mostrar una alerta, el sistema pot iniciar una comunicació preventiva orientada a confirmar la intenció d'arribada, resoldre dubtes o facilitar una modificació abans que es produeixi una cancel·lació.

Perquè l'enviament real funcioni, cal executar el backend FastAPI i configurar les credencials SMTP en un fitxer .env. Sense aquest backend, el dashboard continua funcionant com a eina de suport i pot preparar accions, però no pot enviar correus reals.

8.4. Flux complet d'ús del sistema

El flux complet de la interfície es pot entendre en dues capes: el flux del client i el flux intern de l'hotel.

En el flux del client, l'usuari accedeix a la web pública de reserva, selecciona l'hotel, l'habitació, les dates, el nombre d'hostes i les preferències. Després introdueix les dades personals i confirma la reserva. El sistema mostra una pantalla de confirmació i, si el backend d'email està actiu, envia un correu de confirmació.

En el flux intern de l'hotel, la reserva queda disponible per al dashboard. El sistema calcula la probabilitat de cancel·lació, assigna el perfil, determina el nivell de risc i recupera les accions recomanades. El personal de l'hotel pot consultar la reserva dins de la cartera operativa, obrir-ne la fitxa, revisar les causes i preparar o executar l'acció recomanada.

Aquesta doble capa reflecteix molt bé el funcionament real d'un IDSS. El client només participa en el procés normal de reserva, mentre que la intel·ligència del sistema opera en segon pla, generant suport per a la presa de decisions internes.

El flux complet pot resumir-se així:

Fase	Component del sistema	Descripció del procés	Resultat generat
1. Creació de la reserva	Web pública de reserva	El client introdueix les dades de l'estada, habitació, país, preferències i informació de contacte.	Nova reserva registrada amb les variables necessàries per ser processada pel sistema.
2. Confirmació al client	Web pública + agent d'email	Un cop confirmada la reserva, es mostra una pantalla de confirmació i, si el backend està actiu, s'envia un correu automàtic de confirmació.	Reserva confirmada des del punt de vista del client, sense exposar informació interna del model.
3. Transferència al sistema intern	localStorage/ mecanisme local del navegador	La reserva queda disponible perquè el dashboard intern la pugui recuperar i incorporar al flux d'anàlisi.	Connexió simulada entre el canal públic de reserva i l'eina interna de gestió.
4. Avaluació predictiva	Model XGBoost	El sistema transforma la reserva amb el preprocessament corresponent i calcula la probabilitat de cancel·lació.	Score de cancel·lació expressat com a probabilitat.
5. Assignació de perfil	Mòdul de clustering	La reserva s'assigna al clúster més proper i es tradueix en un perfil TLP operatiu.	Perfil de reserva: Planificador anticipat, Reserva d'última hora, Viatger premium, Turista familiar, Viatger estàndard o Corporatiu fidel.
6. Aplicació del model de coneixement	Regles YAML	El sistema combina el nivell de risc i el perfil TLP per recuperar les accions recomanades.	Canals, timing i actuacions preventives adaptades al cas.

7. Visualització i decisió	Dashboard intern	El personal de l'hotel consulta la reserva, revisa el risc, les causes, el perfil i les accions proposades.	Fitxa d'intervenció orientada a la presa de decisions.
8. Execució o preparació de l'acció	Dashboard + agent d'email	L'usuari pot preparar una acció, marcar-la com a realitzada o enviar un email preventiu si es compleixen les condicions.	Acció operativa registrada, programada o comunicada al client.
9. Seguiment posterior	Monitorització i feedback	Quan es coneix el resultat real de la reserva, aquesta informació pot utilitzar-se per comparar predicció i resultat.	Base per a la revisió del sistema, l'avaluació del rendiment i futurs reentrenaments.

Taula 9: Flux del IDSS

Aquest flux mostra que el sistema no funciona com una eina aïllada de predicció, sinó com un procés complet de suport a la decisió. La reserva entra per un canal públic, és avaluada internament mitjançant models i regles de negoci, i finalment es transforma en una recomanació operativa que pot ser revisada i executada pel personal de l'hotel. D'aquesta manera, la interfície connecta l'experiència del client amb la gestió interna del risc, mantenint sempre separada la informació visible per al client de la informació analítica utilitzada pel dashboard.

8.5. Valor aportat per la interfície

La interfície aporta valor en diversos nivells. En primer lloc, millora la **priorització operativa**. El dashboard no obliga l'equip a revisar manualment totes les reserves, sinó que ordena els casos segons risc, urgència i impacte potencial. Això permet concentrar l'esforç humà en les reserves on una intervenció pot tenir més valor.

En segon lloc, reforça la **gestió del revenue**. El sistema no només mostra la probabilitat de cancel·lació, sinó també el valor econòmic estimat de la reserva. Això permet diferenciar entre una reserva d'alt risc però baix impacte i una reserva d'alt valor que pot justificar una actuació personalitzada.

En tercer lloc, millora la **consistència de les decisions**. Les accions recomanades no depenen només del criteri individual de cada usuari, sinó d'un model de coneixement explícit i revisable. Això ajuda a aplicar criteris més homogenis entre diferents persones o torns de treball.

En quart lloc, facilita la **traçabilitat**. Cada reserva queda associada a una probabilitat, un nivell de risc, un perfil, unes causes i unes accions recomanades. Aquesta informació permet revisar posteriorment per què es va proposar una actuació determinada.

En cinquè lloc, la interfície millora la **separació entre experiència de client i gestió interna**. La web pública ofereix un flux net i senzill de reserva, mentre que el dashboard concentra la informació analítica i operativa. Aquesta separació és clau per evitar exposar al client informació sensible o difícil d'interpretar.

Finalment, la interfície apropa el projecte a un escenari real d'ús. El sistema ja no queda limitat a l'entrenament d'un model en un notebook, sinó que mostra com la predicció pot convertir-se en una eina integrada de suport a la decisió.

8.6. Limitacions i abast de la implementació

La interfície desenvolupada correspon a un prototip funcional local d'un sistema IDSS hotel·ler. Tot i que el flux és complet, el sistema no està connectat a un PMS, CRM o motor de reserves real. Les reserves creades des de la web pública es comparteixen amb el dashboard mitjançant mecanismes locals del navegador, com localStorage i window.name. En un desplegament real, aquesta connexió s'hauria de substituir per una base de dades o una API persistent.

Les accions com trucades, SMS, revisions manuals o garanties tampoc s'executen sobre sistemes externs. El dashboard les prepara, les mostra i les pot programar visualment, però no està integrat amb una centraleta telefònica, una plataforma SMS, un CRM o un gestor de tasques corporatiu.

L'enviament real d'emails sí que està previst, però requereix executar el backend FastAPI i configurar credencials SMTP. Sense aquesta configuració, el sistema continua permetent la simulació del flux de decisió, però no envia correus reals.

També cal remarcar que les recomanacions del sistema s'han d'interpretar com a suport a la decisió, no com a decisions automàtiques obligatòries. L'usuari intern manté sempre la capacitat de revisar el cas, aplicar criteri professional i adaptar l'actuació segons el context. Aquesta limitació és coherent amb la naturalesa d'un IDSS: el sistema ajuda a decidir, però no substitueix completament el criteri humà.

En conjunt, la interfície compleix la funció principal del projecte: demostrar com un model predictiu pot integrar-se en un sistema complet que rep reserves, calcula risc, assigna perfils, aplica regles de negoci i proposa accions operatives alineades amb els objectius de l'hotel.

9. Validació

9.1. Enfocament general de la validació

La validació del sistema s'ha plantejat com un procés estructurat en múltiples nivells, amb l'objectiu de comprovar que cada component funciona correctament de manera individual i que la integració entre components genera un comportament coherent i útil des del punt de vista operatiu.

Cal destacar que la validació d'aquest projecte no s'ha dut a terme en un entorn de producció real ni amb usuaris finals de l'hotel. El sistema és un prototip funcional desenvolupat en un context acadèmic, de manera que les proves s'han realitzat sobre dades del dataset original, simulacions de reserves i verificació manual del comportament del sistema davant de casos concrets. Aquesta limitació és important de tenir en compte a l'hora d'interpretar els resultats de la validació, ja que un desplegament real podria revelar necessitats addicionals que no han estat possibles d'anticipar en aquesta fase.

L'enfocament de validació s'organitza en quatre nivells complementaris. En primer lloc, es validen els components individuals del sistema de manera aïllada: el model predictiu, el mòdul de clustering, les regles del model de coneixement i els elements de la interfície. En segon lloc, es validen les interaccions entre components, comprovant que el flux complet del sistema, des de l'entrada d'una reserva fins a la generació d'una recomanació, es comporta de manera consistent i sense incoherències. En tercer lloc, es realitza una validació mitjançant casos d'ús concrets, seleccionant reserves amb perfils clarament diferenciats i verificant que el sistema genera les prediccions, els perfils i les accions esperades. Finalment, es valida la interfície i l'agent d'email, comprovant que les dues capes de la interfície, la web pública de reserva i el dashboard intern, funcionen correctament i que el flux de comunicació amb el client es comporta de manera adequada.

Aquesta estructura de validació permet cobrir tant la dimensió tècnica del sistema, centrada en el rendiment dels models i la correcció del codi, com la dimensió operativa, orientada a verificar que les recomanacions generades tenen sentit des del punt de vista del negoci hotelier. En un IDSS, aquesta segona dimensió és tan important com la primera, ja que un sistema tècnicament correcte però que genera recomanacions poc útils o difícils d'interpretar no aportaria valor real a l'organització.

9.2. Validació dels components individuals

Model predictiu i pipeline de preprocessament

A més d'avaluar el rendiment del model amb mètriques sobre el conjunt de test, també s'han implementat diferents proves automatitzades per assegurar que el sistema funciona correctament quan es desplega en producció. Aquestes proves permeten verificar que tant el model com el procés de preparació de les dades mantenen el mateix comportament que durant l'entrenament.

Un dels tests més importants comprova el tractament de la variable *arrival_date_year*. Durant el desenvolupament es va decidir considerar aquesta variable com a categòrica i no com a numèrica, ja que els anys no representen una relació matemàtica directa sinó diferents contextos temporals. El test valida que aquesta decisió es manté correctament dins del pipeline de preprocessament.

A més, també es comprova que el sistema és capaç de gestionar valors nous que no havia vist durant l'entrenament. Per exemple, si apareix una reserva corresponent a un any concret, el preprocessador ha de generar correctament les columnes one-hot associades sense provocar errors. Aquesta verificació és especialment important perquè garanteix que el model pugui continuar funcionant de manera estable davant dades reals i canviants.

Un altre conjunt de proves valida que tots els fitxers necessaris per al funcionament del sistema (com el model entrenat, el preprocessador, el fitxer YAML del sistema de coneixement o els resultats del clustering) es troben als directoris esperats dins de l'estructura del projecte. D'aquesta manera s'eviten errors freqüents en entorns de producció relacionats amb configuracions incorrectes o rutes mal definides.

Pel que fa al rendiment del model predictiu, la validació s'ha realitzat sobre un conjunt de test separat, que no s'ha utilitzat ni durant l'entrenament ni durant l'ajust d'hiperparàmetres. Això permet obtenir una estimació realista de la capacitat de generalització del model.

Els resultats obtinguts mostren una accuracy de 0,8404, un recall de 0,8507, una F1 de 0,7906 i una AUC de 0,9241 (tal com ja havíem vist a la Taula 4). Aquestes mètriques indiquen que el model és capaç de distingir de manera consistent entre reserves amb risc de cancel·lació i reserves que probablement es mantindran actives.

El recall elevat és especialment rellevant dins del context del projecte, ja que l'objectiu principal és detectar el màxim nombre possible de cancel·lacions potencials. És preferible generar alguna alerta addicional abans que deixar escapar reserves amb un risc real de cancel·lació. La precision de 0,7383 mostra que aproximadament tres de cada quatre alertes generades pel sistema corresponen efectivament a reserves cancel·lades, un resultat adequat per a un sistema orientat al suport a la decisió.

També s'ha verificat que el preprocessador guardat genera exactament la mateixa transformació de dades en producció que durant l'entrenament del model. Això inclou les imputacions de valors absents, l'escalat de variables numèriques i la codificació one-hot de les variables categòriques. Aquesta coherència és fonamental perquè qualsevol diferència entre entrenament i producció podria afectar negativament les prediccions del sistema.

Mòdul de clustering

La validació del mòdul de clustering s'ha realitzat mitjançant mètriques internes, ja que en aquest cas no existeixen etiquetes reals que permetin comparar directament els grups generats.

El model final obté un valor silhouette de 0,197, que indica una separació moderada però consistent entre els diferents perfils identificats. Encara que no es tracta d'una separació extrema, el resultat és acceptable tenint en compte la naturalesa heterogènia del comportament dels clients hotelers. També s'han analitzat altres mètriques com l'índex de Davies-Bouldin i l'índex de Calinski-Harabasz, que reforcen la idea que la solució amb sis clústers ofereix un bon equilibri entre qualitat estadística i interpretabilitat.

Més enllà de les mètriques numèriques, la validació del clustering s'ha completat amb una revisió qualitativa dels perfils obtinguts. Per a cada clúster s'han analitzat les característiques principals de les reserves, incloent-hi variables relacionades amb l'antelació de la reserva, el valor econòmic, la composició dels clients o el canal de reserva utilitzat.

Aquesta revisió ha permès confirmar que els grups presenten patrons numèricament diferenciats en dimensions operatives rellevants. A partir d'aquests patrons s'han assignat etiquetes interpretatives que faciliten la seva lectura operativa: clients que planifiquen les reserves amb molta antelació, reserves d'última hora, viatgers premium amb imports elevats, famílies o clients corporatius amb comportament més fidel.

Per reforçar aquesta validació, també s'ha entrenat un model auxiliar de Random Forest amb l'objectiu d'identificar quines variables contribueixen més a diferenciar els clústers. Els resultats mostren que les variables més importants coincideixen amb dimensions operatives esperades, com ara la planificació temporal, el valor econòmic de la reserva, la composició dels hostes o el canal comercial. Això aporta consistència addicional als perfils generats pel clustering.

Model de coneixement

La validació del model de coneixement s'ha centrat principalment en comprovar que les regles definides al fitxer YAML siguin coherents, completes i aplicables dins d'un context real d'operació hotelera.

Per una banda, s'han implementat proves automatitzades que recorren tots els perfils generats pel clustering i verifiquen que cadascun disposa d'accions definides per als quatre nivells de risc: BAJO, MEDIO, ALTO i CRITICO. Aquesta comprovació garanteix que el sistema sempre pugui generar una recomanació, independentment del perfil del client o del nivell de risc detectat.

També s'ha validat que el fitxer YAML no contingui estructures antigues o regles residuals procedents de versions anteriors del sistema. Això assegura que tota la lògica de negoci utilitzada pel sistema es basa exclusivament en els perfils actuals del clustering i evita possibles contradiccions entre regles.

A nivell funcional, la validació s'ha completat amb una revisió manual de les accions definides per a cada combinació de perfil i risc. Durant aquesta revisió s'ha comprovat que les

recomanacions siguin coherents amb la situació detectada i que existeixi una progressió lògica entre nivells de risc.

Per exemple, les accions associades a un nivell crític impliquen intervencions més intenses que les associades a nivells baixos o moderats. Això inclou accions com contactes directes amb el client, revisions manuals o notificacions específiques a revenue management.

Finalment, també s'ha verificat que els canals de comunicació recomanats (com email, SMS, trucades telefòniques o revisió manual) siguin adequats per a cada tipus de perfil. D'aquesta manera, el sistema no només detecta el risc de cancel·lació, sinó que també proporciona recomanacions operatives coherents i adaptades al comportament de cada segment de clients.

Cal remarcar que la coherència de les regles amb el domini hotelier s'ha basat en el criteri dels autors del projecte i en els principis experts descrits a la secció 6.2, sense contrast amb professionals del sector. Aquesta limitació es recull a la secció 8.6.

9.3. Validació mitjançant casos d'ús

Per validar el funcionament del sistema de manera integral, s'han definit cinc casos d'ús representatius que cobreixen els escenaris operatius més rellevants. Cada cas s'ha executat sobre el sistema real, verificant que el flux complet (des de la creació de la reserva fins a la generació de la recomanació) funcioni de manera coherent.

Cas 1: Reserva d'alt risc amb perfil planificador anticipat

Es crea una reserva des de la web pública per a una estada de 3 nits al Resort Hotel, amb 2 hostes, règim mitja pensió i sense dipòsit. El país d'origen és el Regne Unit (risc mitjà) i el client no té historial de cancel·lacions. Tot i això, el sistema detecta 365 dies d'antelació i un valor estimat de 708€, generant una probabilitat del 76,1% i classificant-la com a risc ALTO. El perfil assignat és Reserva d'Última Hora via canal directe. L'acció recomanada és contactar directament el client per confirmar la intenció d'arribada i reduir la incertesa abans de la data prevista. Aquest cas valida que el sistema és capaç de detectar risc elevat fins i tot en clients sense historial negatiu quan altres factors com l'antelació i el valor econòmic ho justifiquen.

La imatge mostra una interfície d'usuari amb dos panells principals. El panell esquerre, titulat 'Ordenadas por urgencia de tratamiento', presenta una llista de reserves amb icones de risc (R per alt, C per baix) i identificadors. El panell dret, titulat 'WEB-7137935 - Resort Hotel', mostra els detalls d'una reserva classificada com a 'ALTO - 76,1%' i 'Pendiente'. Aquesta secció està dividida en tres columnes: 'QUE PASA' (explica el risc basat en l'antelació i el valor), 'QUE HACER' (recomana contactar el client) i 'PARA QUE SIRVE' (recomana reduir l'incertesa). També inclou un formulari amb camps per a: Perfil TLP (Reserva de Última Hora), Llegada (25 May 2027), Valor estimado (708 €), Canal (Direct - Direct), Tipo deposito (No Deposit), Estancia (3 noches - 2 huéspedes), Email huésped (p@gmail.com), Habitación y regimen (Tipo C - HB) i Historial (Sin cancelaciones previas registradas). A la dreta, un altre panell confirma la reserva ('RESERVA CONFIRMADA WEB-7137935') i mostra els detalls de la reserva: Hotel (Resort Hotel), Fechas (25 de mayo de 2027), Noches y huéspedes (3 noches - 2 huéspedes), Huésped (a), Email (p@gmail.com), Habitación (Superior - HB), Depósito (No Deposit) i Precio total (708 €). El status és 'Pendiente' i hi ha un botó 'Nueva reserva'.

Figura 36: Exemples de la reserva d'alt risc amb perfil de planificador anticipat

Cas 2: Reserva de baix risc

Es crea una reserva des de la web pública per a una estada d'1 nit al City Hotel, amb 2 hostes, règim només allotjament i dipòsit Non Refund. El país d'origen és de risc baix (NOR) i el client no té historial de cancel·lacions. El sistema genera una probabilitat de cancel·lació del 7,4%, el classifica com a risc BAJO i l'assigna al perfil Reserva d'Última Hora via canal directe. L'acció recomanada és enviar un email personalitzat amb incentiu o condicions clares, amb l'objectiu de deixar la reserva en seguiment rutinari i actuar només si apareixen noves senyals. Aquest cas valida que el sistema no genera falses alarmes sobre reserves de baix risc i que les accions recomanades són proporcionades a la situació.




Figura 37: Exemple d'una reserva de baix risc

Cas 3: Reserva d'última hora

Es crea una reserva des del formulari públic per a una estada d'1 nit al City Hotel, amb 2 hostes, règim amb esmorzar i dipòsit Non Refund. Un cop confirmada, la web mostra la pantalla de confirmació amb el localitzador WEB-7393221 i el missatge d'enviament de confirmació per email. Simultàniament, la reserva apareix al dashboard intern amb el perfil Reserva d'Última Hora i les accions recomanades corresponents: enviar email immediat de confirmació amb pre-check-in digital, oferir upsell de disponibilitat immediata i validar dades mínimes de contacte. Aquest cas valida el flux complet d'extrem a extrem: la reserva creada pel client és processada correctament pel motor IDSS i apareix al dashboard amb risc, perfil i accions calculades sense intervenció manual.




Figura 37: Exemple d'una reserva d'última hora

Cas 4: Reserva corporativa de risc crític

Aquesta reserva prové del dataset històric i correspon a un client corporatiu amb 26 cancel·lacions prèvies registrades, feta 275 dies abans de l'arribada des d'Itàlia (país de risc alt). El sistema genera una probabilitat del 98,8% i la classifica com a risc CRÍTIC. El perfil assignat és Corporatiu Fidel, assignat des del clúster 5. Les variables distintives del clúster indiquen repetició o relació comercial i major importància del CRM. Les accions recomanades són trucades prioritàries: activar revisió conjunta entre reserves i account manager abans de modificar condicions comercials, i contactar el responsable corporatiu per confirmar si existeix un canvi estructural en els viatges d'empresa. Si es detecta risc repetit, el sistema recomana obrir revisió de l'acord corporatiu. Aquest cas valida que el sistema no aplica accions automàtiques agressives davant un client corporatiu d'alt risc, sinó que prioritza la protecció de la relació comercial i la revisió manual abans de qualsevol intervenció restrictiva.

Lectura concreta del caso

Esta reserva tiene 98.8 % de probabilidad estimada de cancelacion. Llega el 4 October 2015 y se hizo con 275 días de antelación. Hay 26 cancelacion(es) previa(s) asociadas. El país de origen (Italia (ITA)) esta marcado como riesgo alto en las reglas del IDSS.

Probabilidad de cancelacion critica calculada por XGBoost

Perfil TLP asignado desde el cluster 5: Corporativo Fiel

Variables distintivas del cluster: repetición o relación comercial; mayor importancia del CRM; confirmación con contacto corporativo

La recomendación sale del perfil Corporativo Fiel, asignado por cluster 5, y del nivel de riesgo calculado para la reserva.

Figura 38: Lectura concreta del client 26

Opciones de actuacion

1

Activar revisión conjunta entre reservas y account manager antes de modificar condiciones comerciales.

LLAMADA

Recomendado para una reserva critico: permite confirmar intencion, resolver dudas y registrar la respuesta.
Programar 10 o 5 o 2 dias antes de la llegada. Se puede aplicar sola o combinada con otras opciones del plan.

Preparar llamada

Marcar realizada

2

Llamada prioritaria al responsable corporativo para confirmar si existe cambio estructural en viajes de empresa.

LLAMADA

Recomendado para una reserva critico: permite confirmar intencion, resolver dudas y registrar la respuesta.
Programar 10 o 5 o 2 dias antes de la llegada. Se puede aplicar sola o combinada con otras opciones del plan.

Preparar llamada

Marcar realizada

3

Si se detecta riesgo repetido, abrir revisión del acuerdo corporativo y condiciones de cancelación futuras.

REVISION

Figura 39: opcions d'actuació proposades

Cas 5: Enviament de mail amb l'agent

Aquest cas d'ús es basa en l'agent d'IA integrat al sistema per gestionar comunicacions preventives amb els clients. Es crea una nova reserva des de la interfície amb un correu electrònic vàlid i el sistema la classifica com a risc ALTO o CRÍTIC. A partir del perfil TLP assignat, el nivell de risc i les regles de negoci, el dashboard activa l'opció d'enviar una comunicació personalitzada al client.

Quan l'usuari executa aquesta acció, la interfície envia les dades de la reserva a l'agent d'email, que funciona com un backend local. Aquest agent utilitza l'API d'OpenAI per generar un missatge adaptat al context del client, tenint en compte aspectes com el tipus de reserva, el risc de cancel·lació, el perfil assignat i l'acció recomanada pel sistema. Un cop generat el text, l'agent envia el correu mitjançant SMTP amb el compte configurat.

Aquest cas valida que el sistema no només calcula el risc i proposa accions, sinó que també pot executar una actuació operativa real i personalitzada, convertint la recomanació del dashboard en una comunicació directa amb el client. A continuació un exemple del mail que es rebria:



Figura 40: mail personalitzat per a reserva classificada com a crítica

9.4. Limitacions de la validació

La validació realitzada en aquest projecte presenta diverses limitacions importants que convé tenir en compte a l'hora d'interpretar els resultats obtinguts.

En primer lloc, totes les proves s'han dut a terme en un entorn local i acadèmic, sense cap desplegament en un hotel real ni amb usuaris finals del sector. Això implica que les conclusions sobre la utilitat operativa del sistema es basen en el criteri dels autors, no en observació empírica de comportament real d'usuaris.

En segon lloc, les regles de negoci del model de coneixement s'han definit a partir dels principis experts descrits a la secció 6.2, sense validació ni contrast amb professionals del sector hotelier. És possible que algunes recomanacions no siguin òptimes per a contextos operatius específics, o que hi hagi patrons de decisió rellevants que el sistema no contempli.

En tercer lloc, la validació del model predictiu s'ha realitzat sobre una mostra de 5.000 reserves extretes aleatòriament del dataset original. Tot i que la mostra és representativa, la seva mida limitada pot afectar la fiabilitat de les mètriques obtingudes, especialment per a perfils de reserva menys freqüents.

En quart lloc, no s'ha implementat cap mecanisme de feedback real que permeti comparar les prediccions del sistema amb els resultats finals de les reserves. Sense aquesta informació, no és possible avaluar si les accions recomanades han tingut efectivament un impacte sobre la taxa de cancel·lació.

Finalment, la comunicació entre la web pública i el dashboard es basa en mecanismes del navegador no persistents, cosa que limita la robustesa del flux complet en escenaris d'ús real. Un desplegament en producció requeriria substituir aquests mecanismes per una solució més estable i segura.

10. Treball futur i millores

El sistema desenvolupat en aquest projecte constitueix un prototip funcional que cobreix el cicle complet d'un IDSS hotelier, des de la predicció fins a la recomanació operativa. No obstant això, existeixen diverses línies de millora que podrien incrementar significativament el seu valor pràctic. Aquestes millores es poden organitzar en tres horitzons temporals: curt, mig i llarg termini.

A curt termini, les millores prioritàries es concentren en consolidar el prototip actual. En primer lloc, caldria completar els apartats de validació amb casos d'ús reals documentats, il·lustrant com el sistema respon davant de reserves amb perfils clarament diferenciats i verificant que les recomanacions generades són coherents amb l'expectativa de negoci. En segon lloc, seria convenient incorporar exemples reals dels correus electrònics generats per l'agent d'email, tant per al flux de confirmació de reserva com per al flux preventiu en casos d'alt risc.

A mig termini, les millores s'orienten a fer el sistema més robust i proper a un entorn de producció real. Una de les limitacions més rellevants del prototip actual és que la comunicació entre la web pública de reserva i el dashboard intern es basa en mecanismes locals del navegador, com ara localStorage i window.name. En un desplegament real, aquesta connexió hauria de substituir-se per una base de dades persistent o una API que garantis la integritat i la traçabilitat de les reserves. De manera complementària, seria necessari implementar un mecanisme de feedback real que permeti recollir el resultat final de cada reserva i comparar-lo amb la predicció generada. Aquesta informació no sols permetria avaluar el rendiment del model al llarg del temps, sinó que també possibilitaria detectar possibles desviacions en el comportament dels clients o en les condicions del mercat. Igualment, ampliar el dataset de treball més enllà de les 5.000 reserves utilitzades milloraria la representativitat del model i la seva capacitat de generalització. Finalment, una fase pilot amb personal intern de l'hotel aportaria informació molt valuosa sobre la usabilitat del dashboard, la claredat de les accions recomanades i la integració del sistema en els fluxos de treball reals.

A llarg termini, les millores apunten a una integració més profunda del sistema dins de l'ecosistema tecnològic hotelier i a una extensió del seu abast funcional. En primer lloc, la integració amb un PMS o CRM real permetria que el sistema accedís directament a les dades de reserves en temps real, eliminant la necessitat d'exportacions manuals i garantint que les prediccions es generin en el moment òptim. En segon lloc, un mecanisme de reentrenament periòdic automatitzat asseguraria que el model es mantingui actualitzat davant de canvis en els patrons de reserva, en la demanda estacional o en les polítiques comercials de l'hotel. En tercer lloc, el sistema podria estendre's a altres problemes rellevants en la gestió hotelera, com ara la predicció de no-shows, la detecció d'oportunitats d'upselling o la personalització d'ofertes segons el perfil del client. Finalment, explorar l'ús de models de sèries temporals o de tècniques que capturin millor la dependència temporal entre reserves podria millorar la sensibilitat del sistema davant de l'estacionalitat i dels patrons de demanda a curt termini.

En conjunt, el sistema proposat ofereix una base sòlida sobre la qual construir un IDSS hotelier cada vegada més complet, integrat i orientat a la presa de decisions. El seu valor no rau únicament en les capacitats actuals, sinó també en l'arquitectura modular que facilita la incorporació progressiva de noves millores sense necessitat de redissenyar el conjunt del sistema.

11. Conclusions

Aquest projecte ha permès desenvolupar un prototip funcional d'un sistema intel·ligent de suport a la decisió orientat a la gestió de cancel·lacions en reserves hoteleres. El treball no s'ha limitat a construir un model predictiu, sinó que s'ha plantejat des d'una perspectiva més àmplia, pròpia d'un IDSS, en què la predicció és només una part d'un procés de decisió complet. En aquest sentit, el sistema integra preprocessament de dades, modelització supervisada, clustering, un model de coneixement basat en regles de negoci, una interfície operativa i mecanismes de comunicació amb el client.

Un dels principals resultats del projecte és la construcció d'un model capaç d'estimar la probabilitat de cancel·lació d'una reserva a partir de la informació disponible en el moment de la seva creació. Després de comparar diferents famílies de models, s'ha seleccionat XGBoost com a model final, ja que ha mostrat el millor equilibri entre capacitat predictiva, recall, F1-score i AUC. Aquesta elecció és coherent amb el context del problema, ja que en la gestió hotelera és especialment important detectar reserves amb risc de cancel·lació sense generar un volum excessiu de falses alarmes que pugui saturar l'operativa de l'hotel.

A més del model predictiu, el projecte ha incorporat un mòdul de clustering amb l'objectiu d'identificar perfils operatius de reserves. Aquesta part ha estat especialment important perquè ha permès complementar la probabilitat de cancel·lació amb una lectura més contextual del tipus de reserva. Inicialment, el clustering aplicat sobre les dades preprocessades del model supervisat no generava perfils interpretables, fet que va evidenciar la necessitat de construir una representació específica per al perfilat. La versió final, basada en variables més compactes i interpretables, ha permès definir perfils com el planificador anticipat, la reserva d'última hora, el viatger premium, el turista familiar, el viatger estàndard i el corporatiu fidel. Aquests perfils no substitueixen el model predictiu, però ajuden a adaptar millor les recomanacions del sistema.

Un altre element clau ha estat la definició del model de coneixement. Les regles de negoci permeten transformar la probabilitat de cancel·lació i el perfil en accions concretes, com ara enviar un recordatori, preparar una trucada, revisar una reserva, contactar amb el client o escalar el cas a revenue management. Aquesta capa és la que converteix el projecte en un veritable sistema de suport a la decisió, ja que evita que la sortida del model quedi reduïda a un simple score numèric. El sistema no només indica que una reserva té risc, sinó que proposa una actuació adaptada al seu context.

La interfície desenvolupada reforça aquesta orientació pràctica. D'una banda, la web pública de reserva simula l'entrada d'una nova reserva des del punt de vista del client. De l'altra, el dashboard intern permet al personal de l'hotel consultar les reserves prioritzades, veure el risc de cancel·lació, el perfil assignat, el valor econòmic estimat i les accions recomanades. Aquesta separació entre el flux públic del client i el flux intern de decisió és coherent amb un escenari real d'ús hotel·ler, on la informació analítica i les recomanacions operatives han de quedar reservades als equips interns.

Des del punt de vista de negoci, el sistema aporta valor perquè ajuda a prioritzar recursos i a reduir la incertesa en la gestió de l'ocupació. No totes les reserves amb risc requereixen la mateixa actuació: una reserva premium pot justificar una intervenció personalitzada, mentre

que una reserva estàndard de baix valor pot gestionar-se mitjançant canals automàtics. Aquesta capacitat d'adaptar la resposta segons el risc, el perfil i l'impacte econòmic permet que el sistema sigui més útil i realista que un model de classificació aïllat.

En conclusió, el projecte ha aconseguit avançar des d'un problema predictiu de cancel·lacions fins a un prototip complet d'IDSS hotelier. La solució combina dades, models de Machine Learning, perfilat de reserves, coneixement expert i una interfície operativa. El seu valor principal no es troba únicament en estimar la probabilitat de cancel·lació, sinó en transformar aquesta estimació en recomanacions concretes que poden ajudar l'hotel a protegir ingressos, gestionar millor l'inventari i prendre decisions més informades.